Немного об алгоритмах консенсуса. Казалось бы, при чем тут Node.js?

Андрей Печкуров

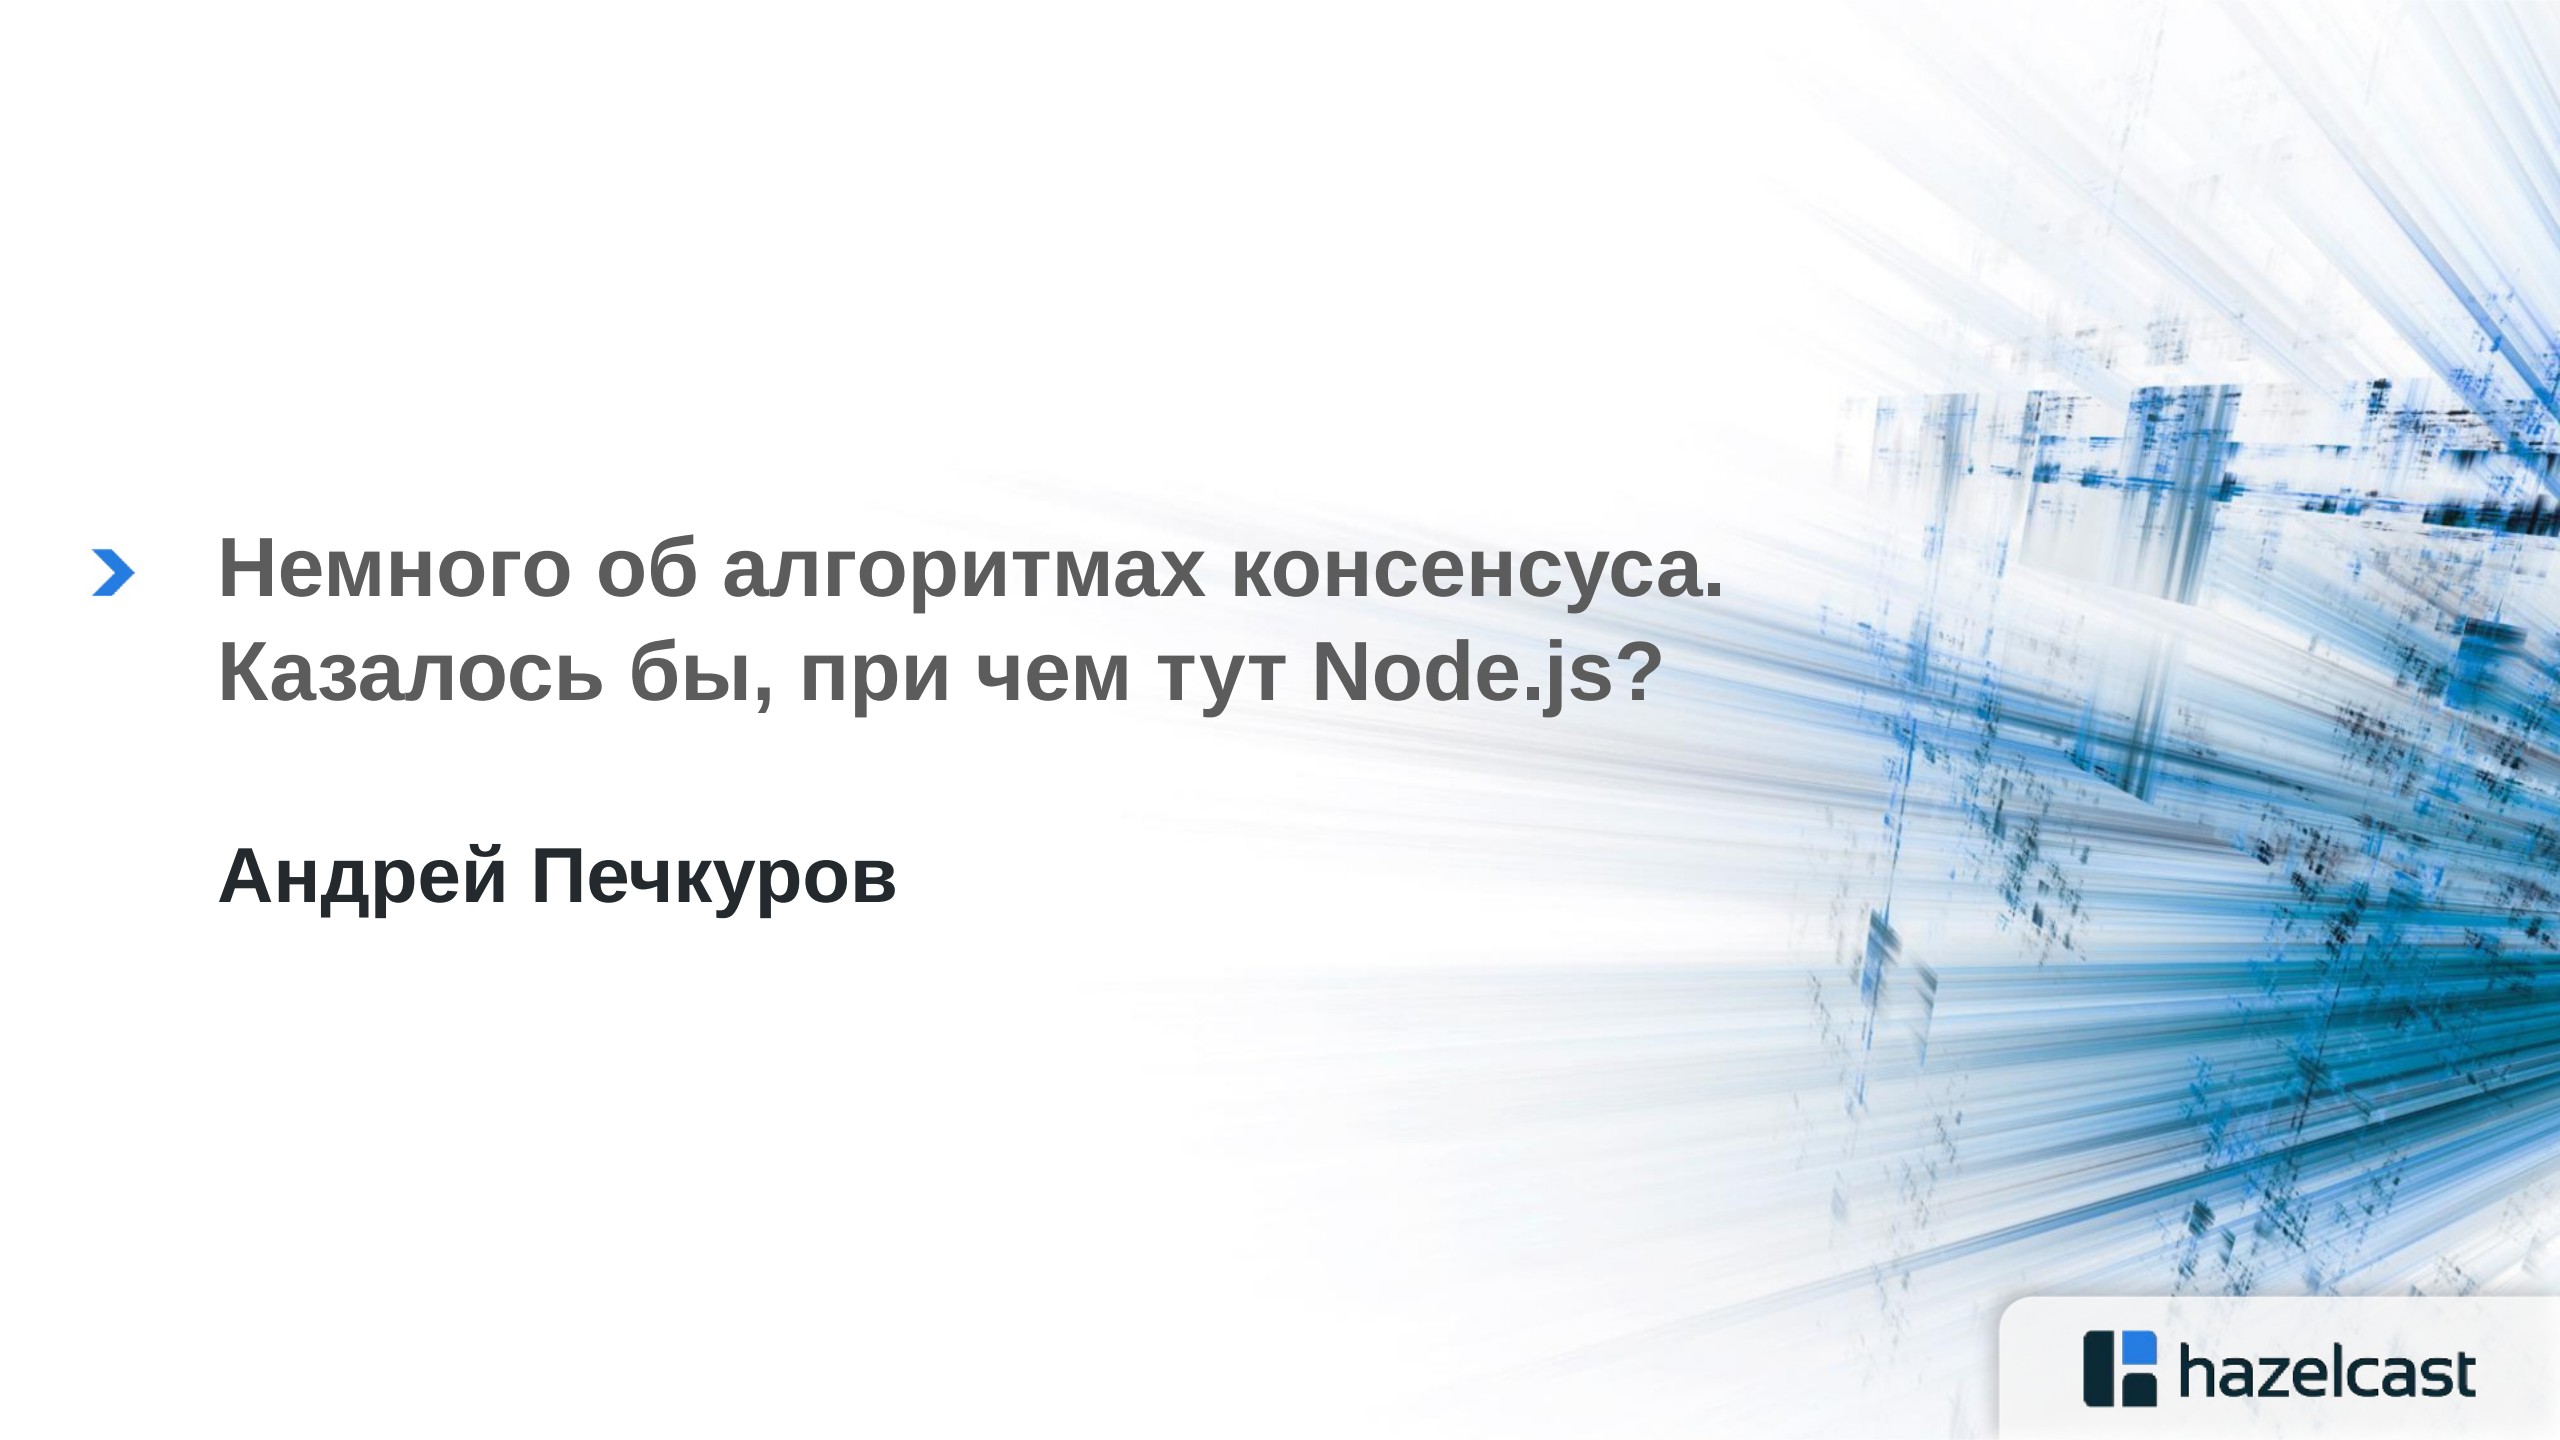

О докладчике

- Пишу на Java (очень долго), Node.js (долго)
- Node.js core collaborator
- Интересы: веб, архитектура, распределенные системы, производительность
- Можно найти тут:
  - https://twitter.com/AndreyPechkurov
  - https://github.com/puzpuzpuz
  - https://medium.com/@apechkurov

Исходная задача

Service A

Service B

Service C

Protected service

Исходная задача

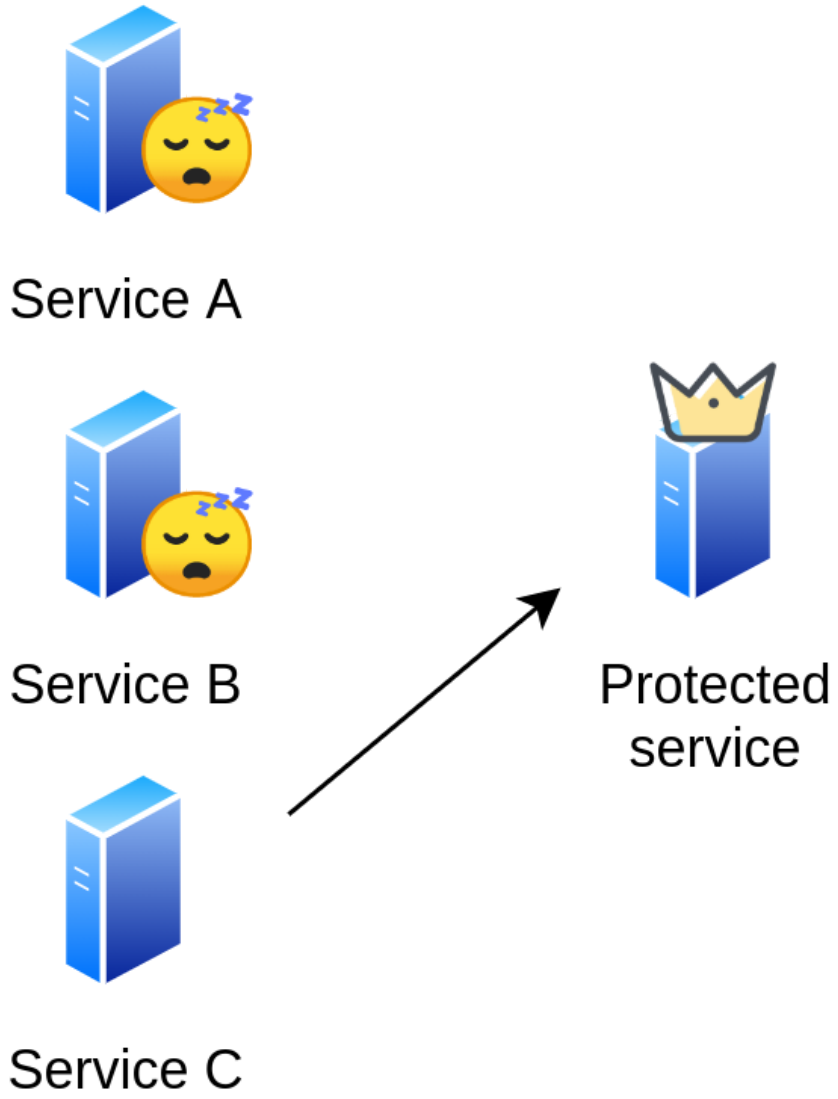

Возможное решение

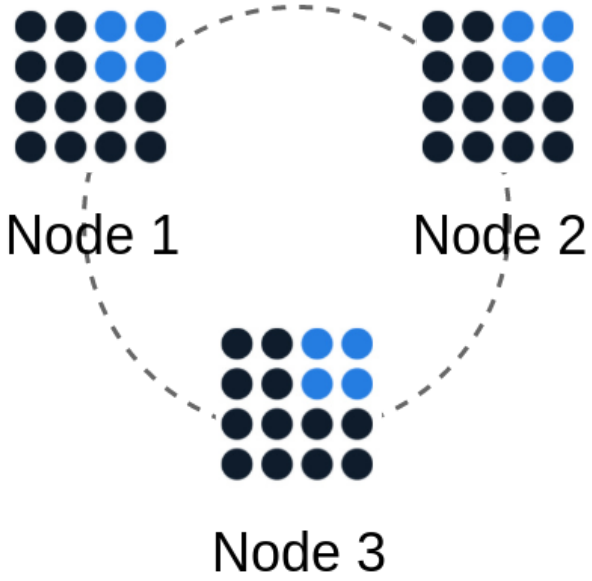

Service A

Service B

Service C

Protected service

Возможное решение

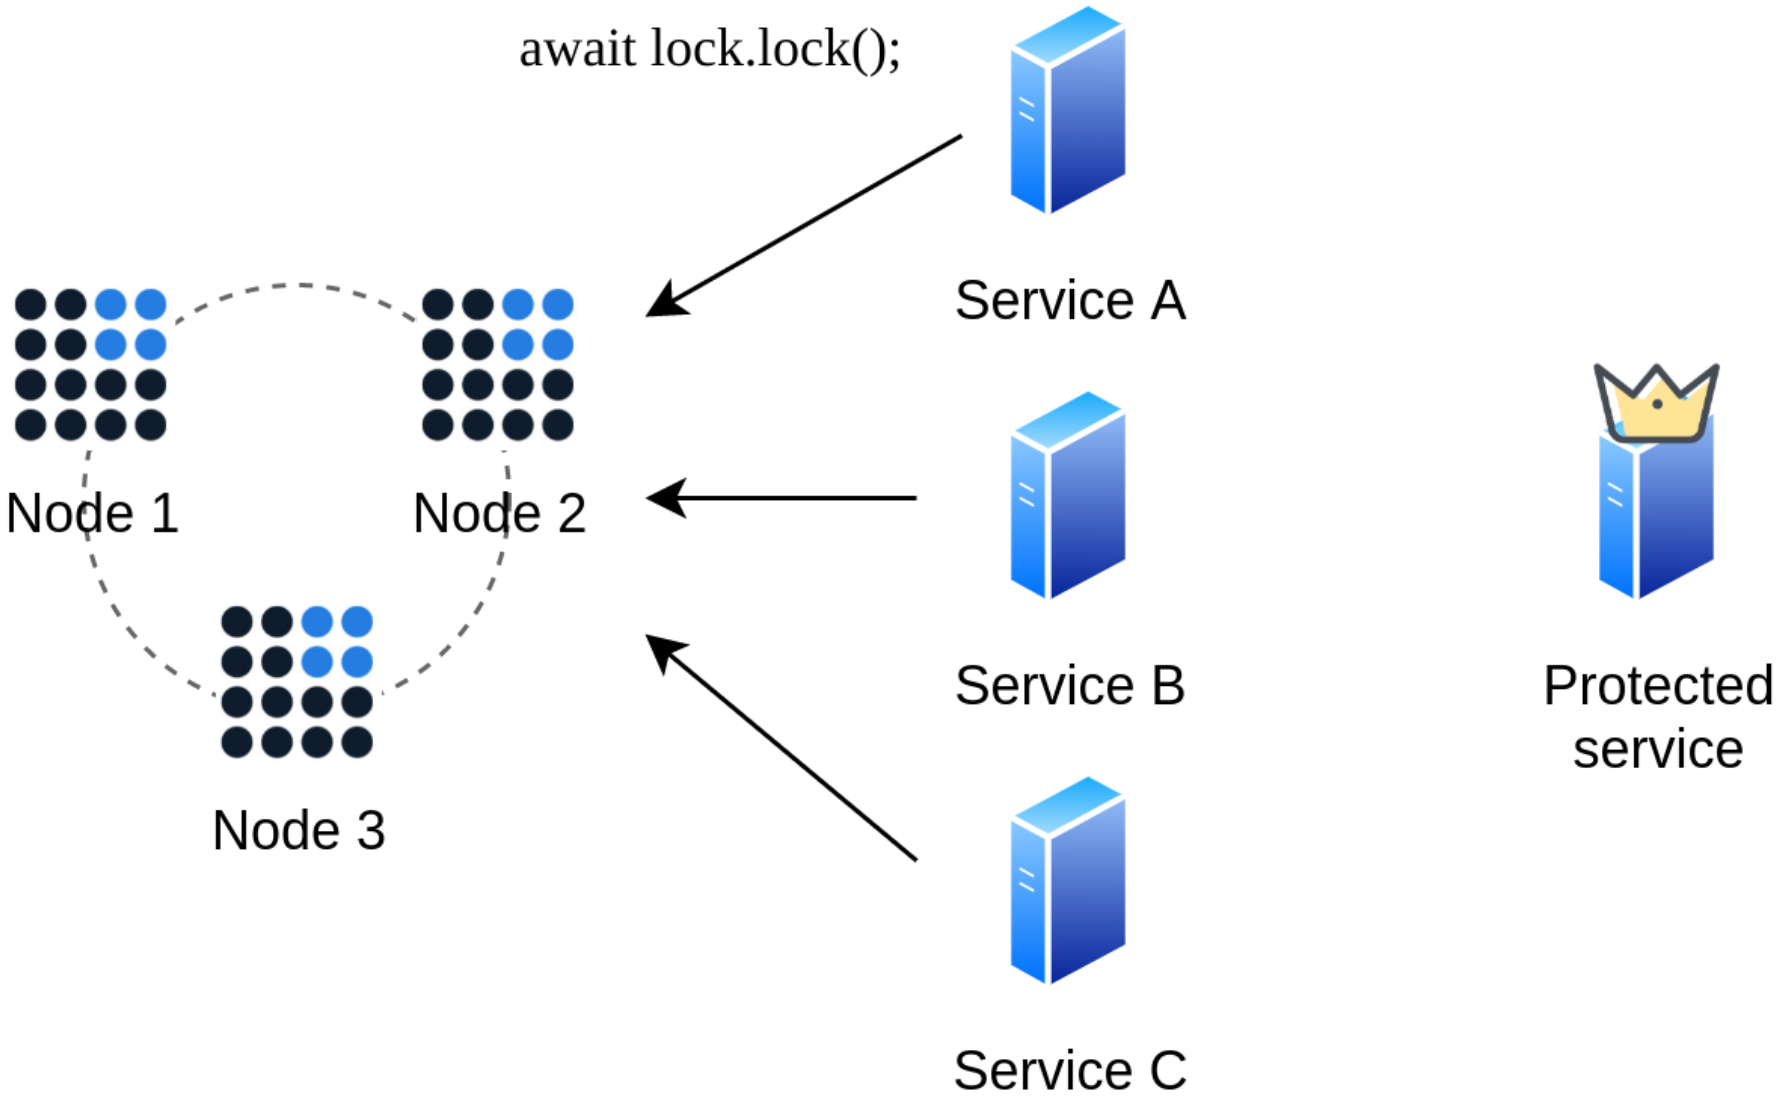

Возможное решение

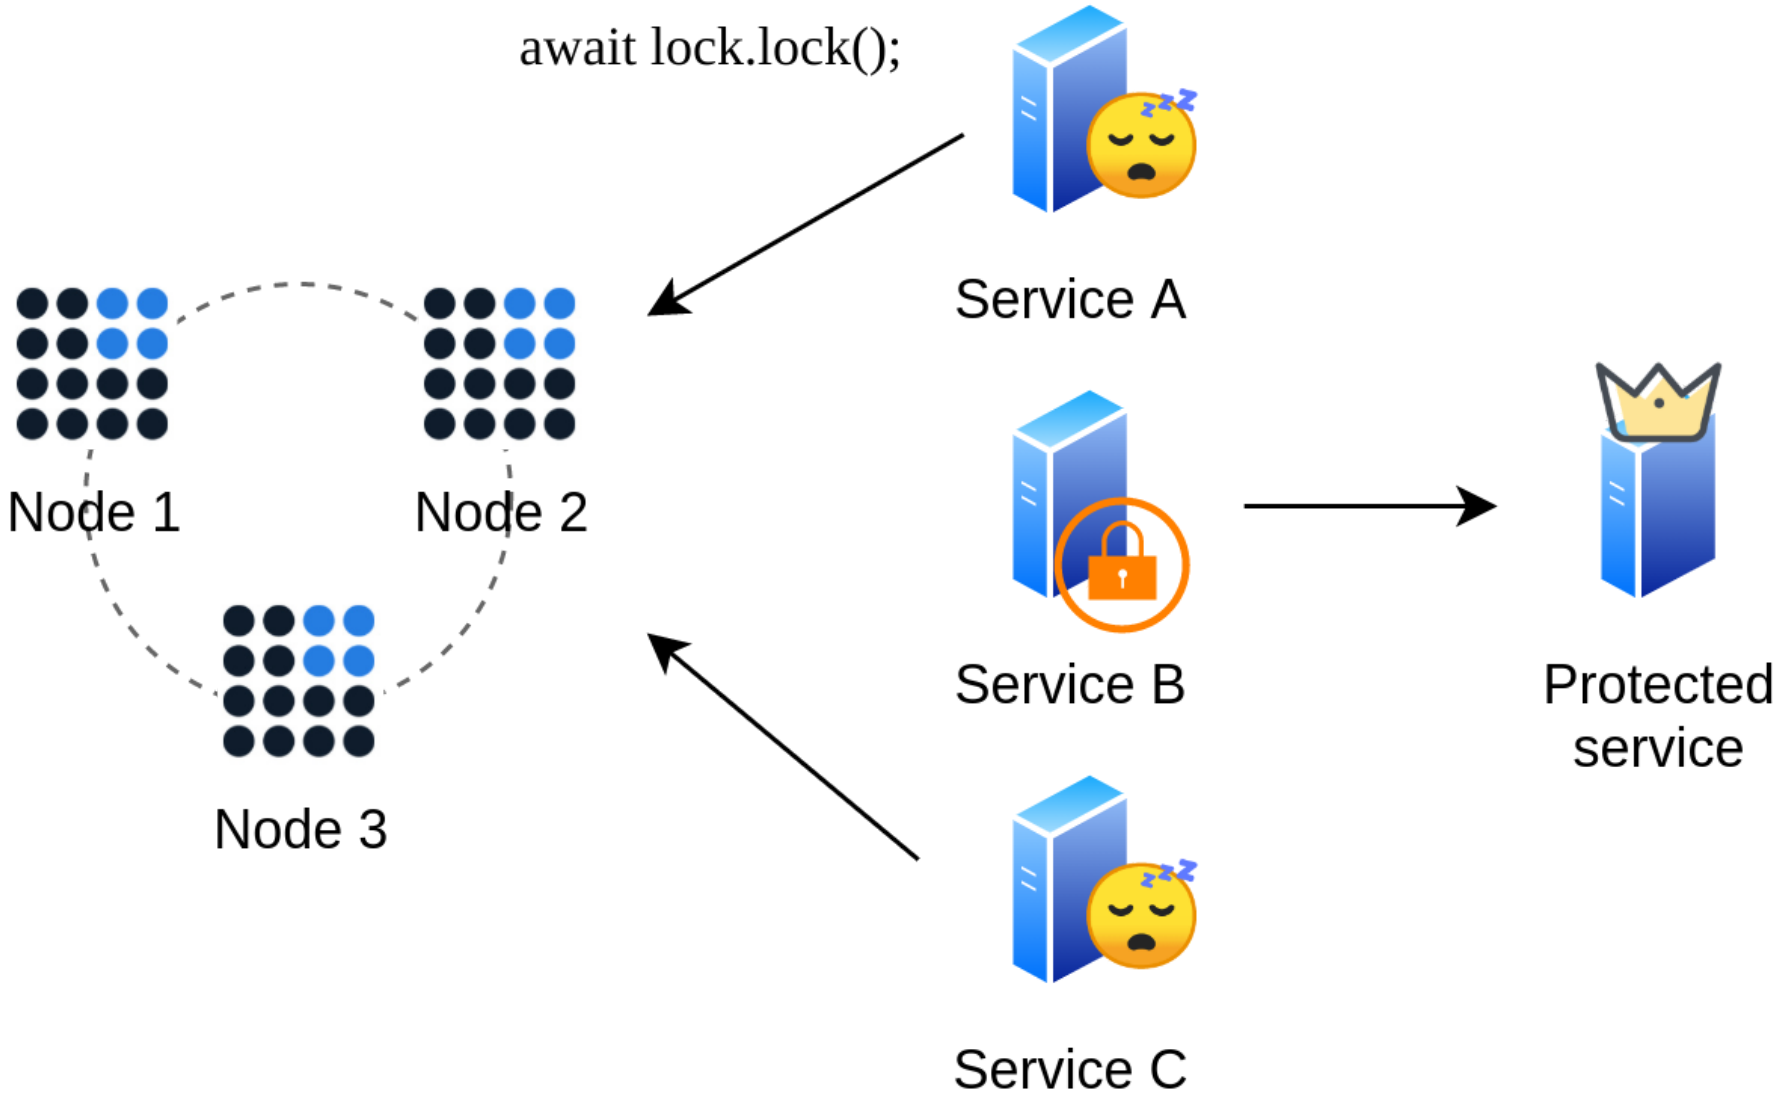

- Hazelcast In-Memory Data Grid (IMDG)
- Большой набор распределенных структур данных
- Показательный пример - `Map`, который часто используют как кэш
- Написана на Java, умеет embedded и standalone режимы
- Хорошо масштабируется вертикально и горизонтально
- Часто используется в high-load и low-latency приложениях
- Области применения: IoT, in-memory stream processing, payment processing, fraud detection и т.д.

Hazelcast IMDG Node.js client

- https://github.com/hazelcast/hazelcast-nodejs-client
- P.S. А вот доклад про историю оптимизаций: https://youtu.be/CSnmpbZsVD4

Старая реализация распределенных lock'ов

```
const lock = await client.getLock('my-lock');

await lock.lock();
try {
    // "защищенный" код
    // (доступен только владельцу)
} finally {
    await lock.unlock();
}
```

Хьюстон, у нас проблема

- В 2017 Kyle Kingsbury (a.k.a. aphyr) потестировал Hazelcast
- https://jepsen.io/analyses/hazelcast-3-8-3

Как это работает в условиях network partition

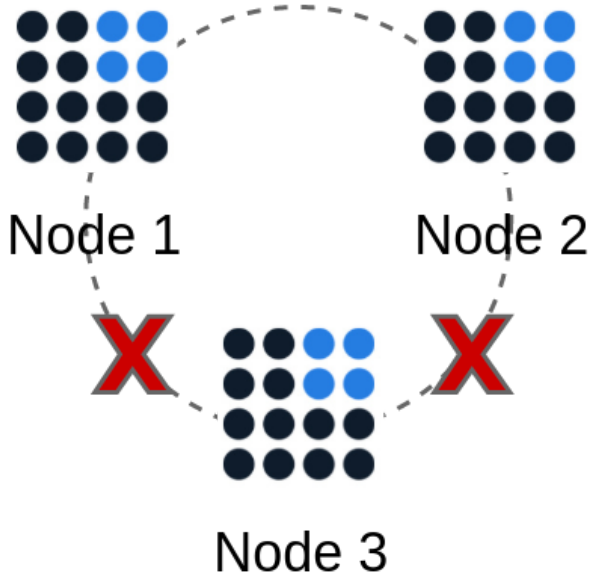

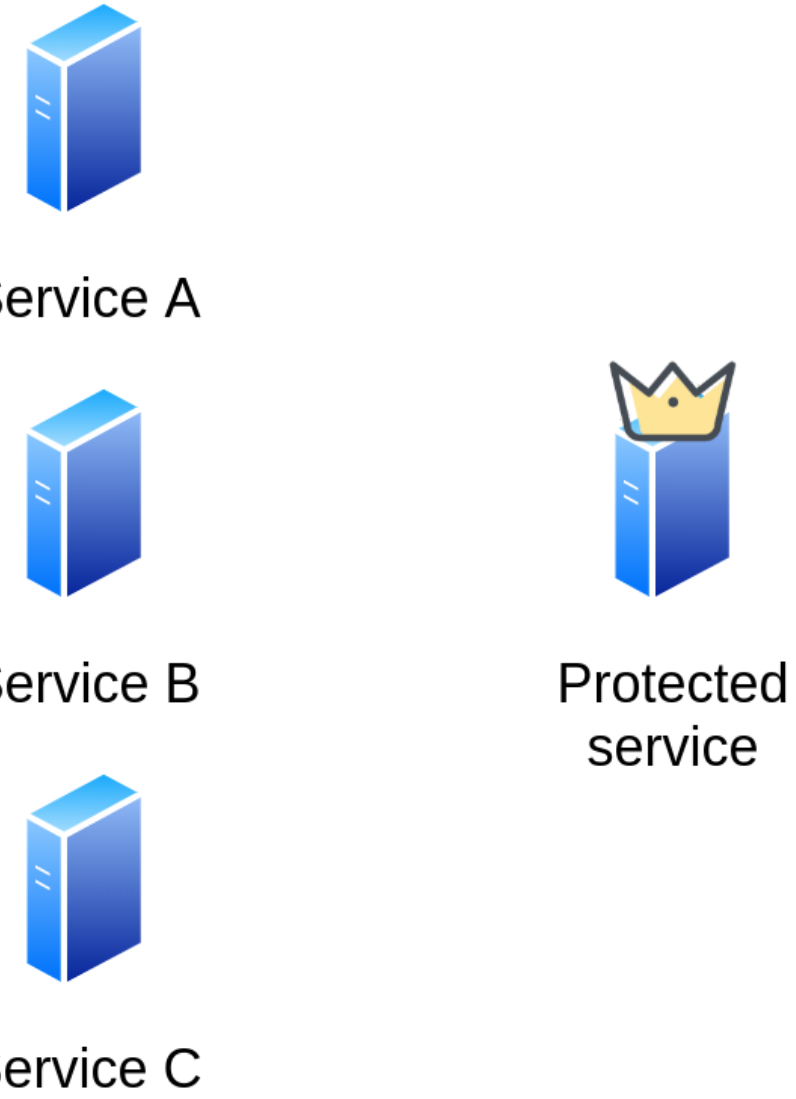

Как это работает в условиях network partition

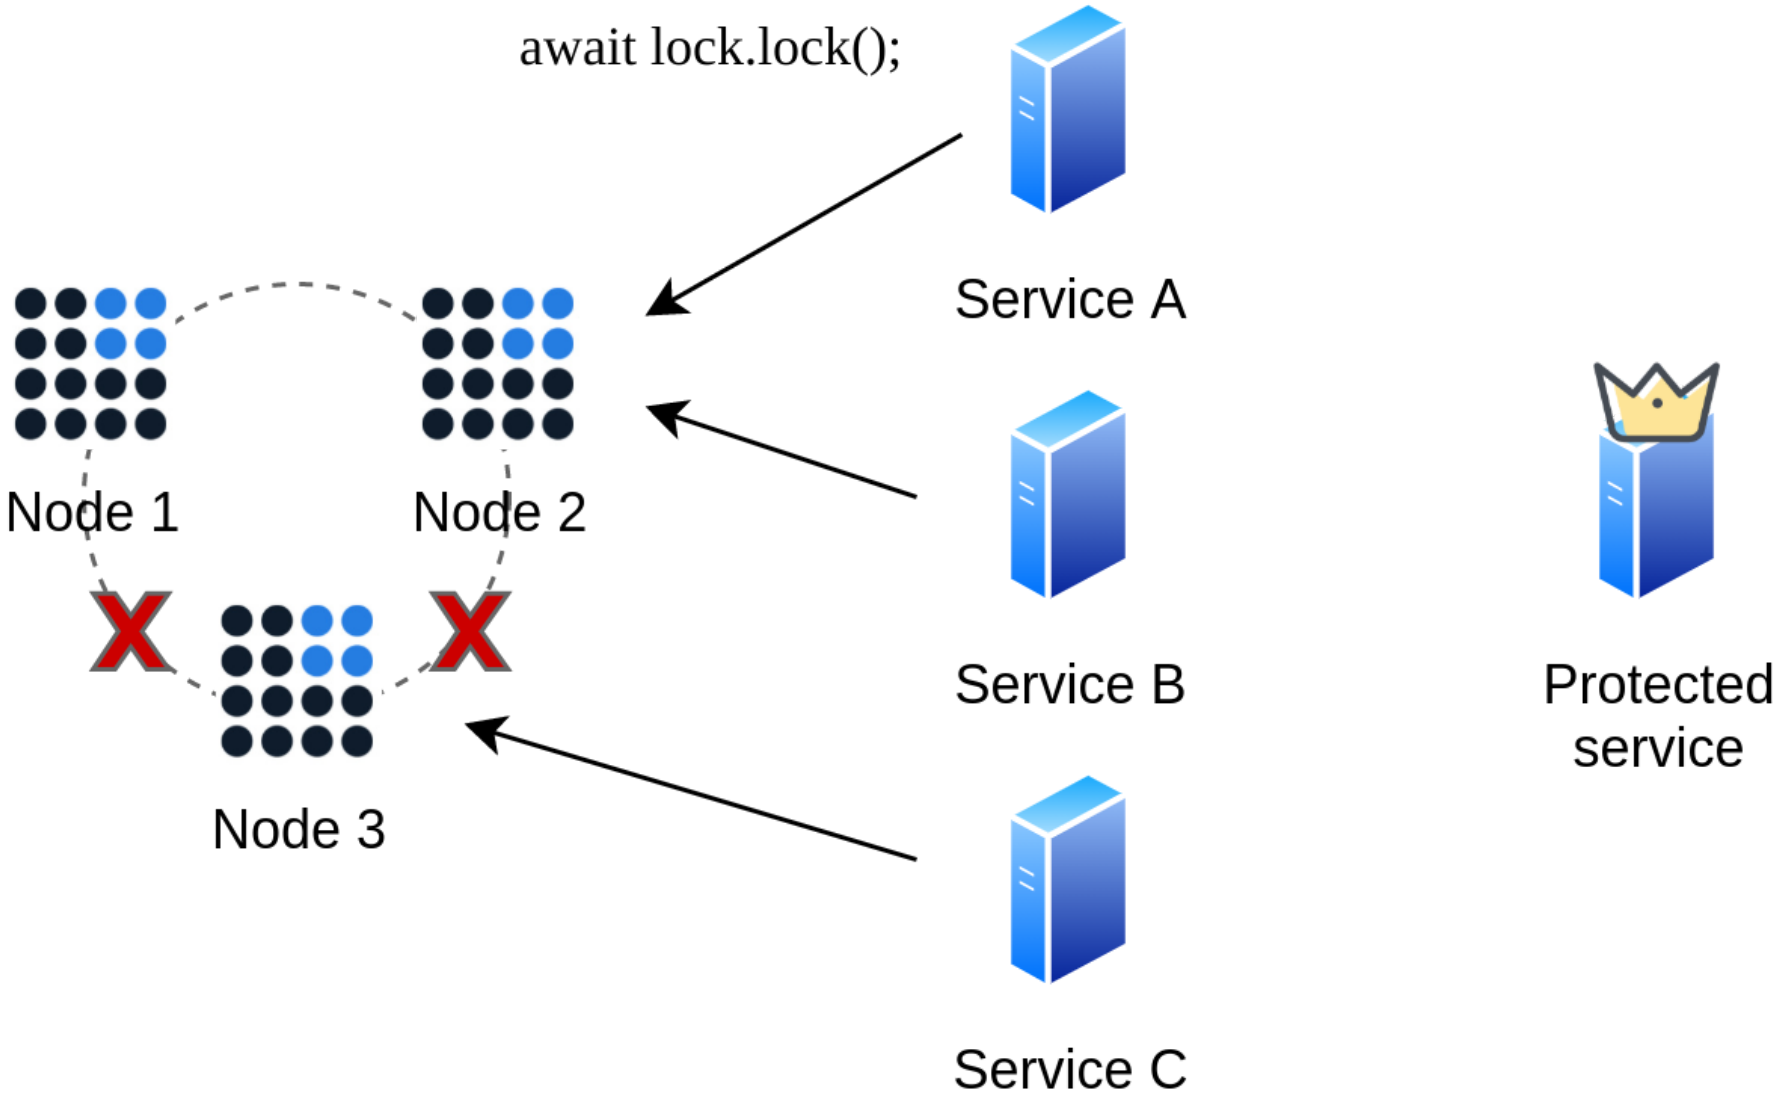

Как это работает в условиях network partition

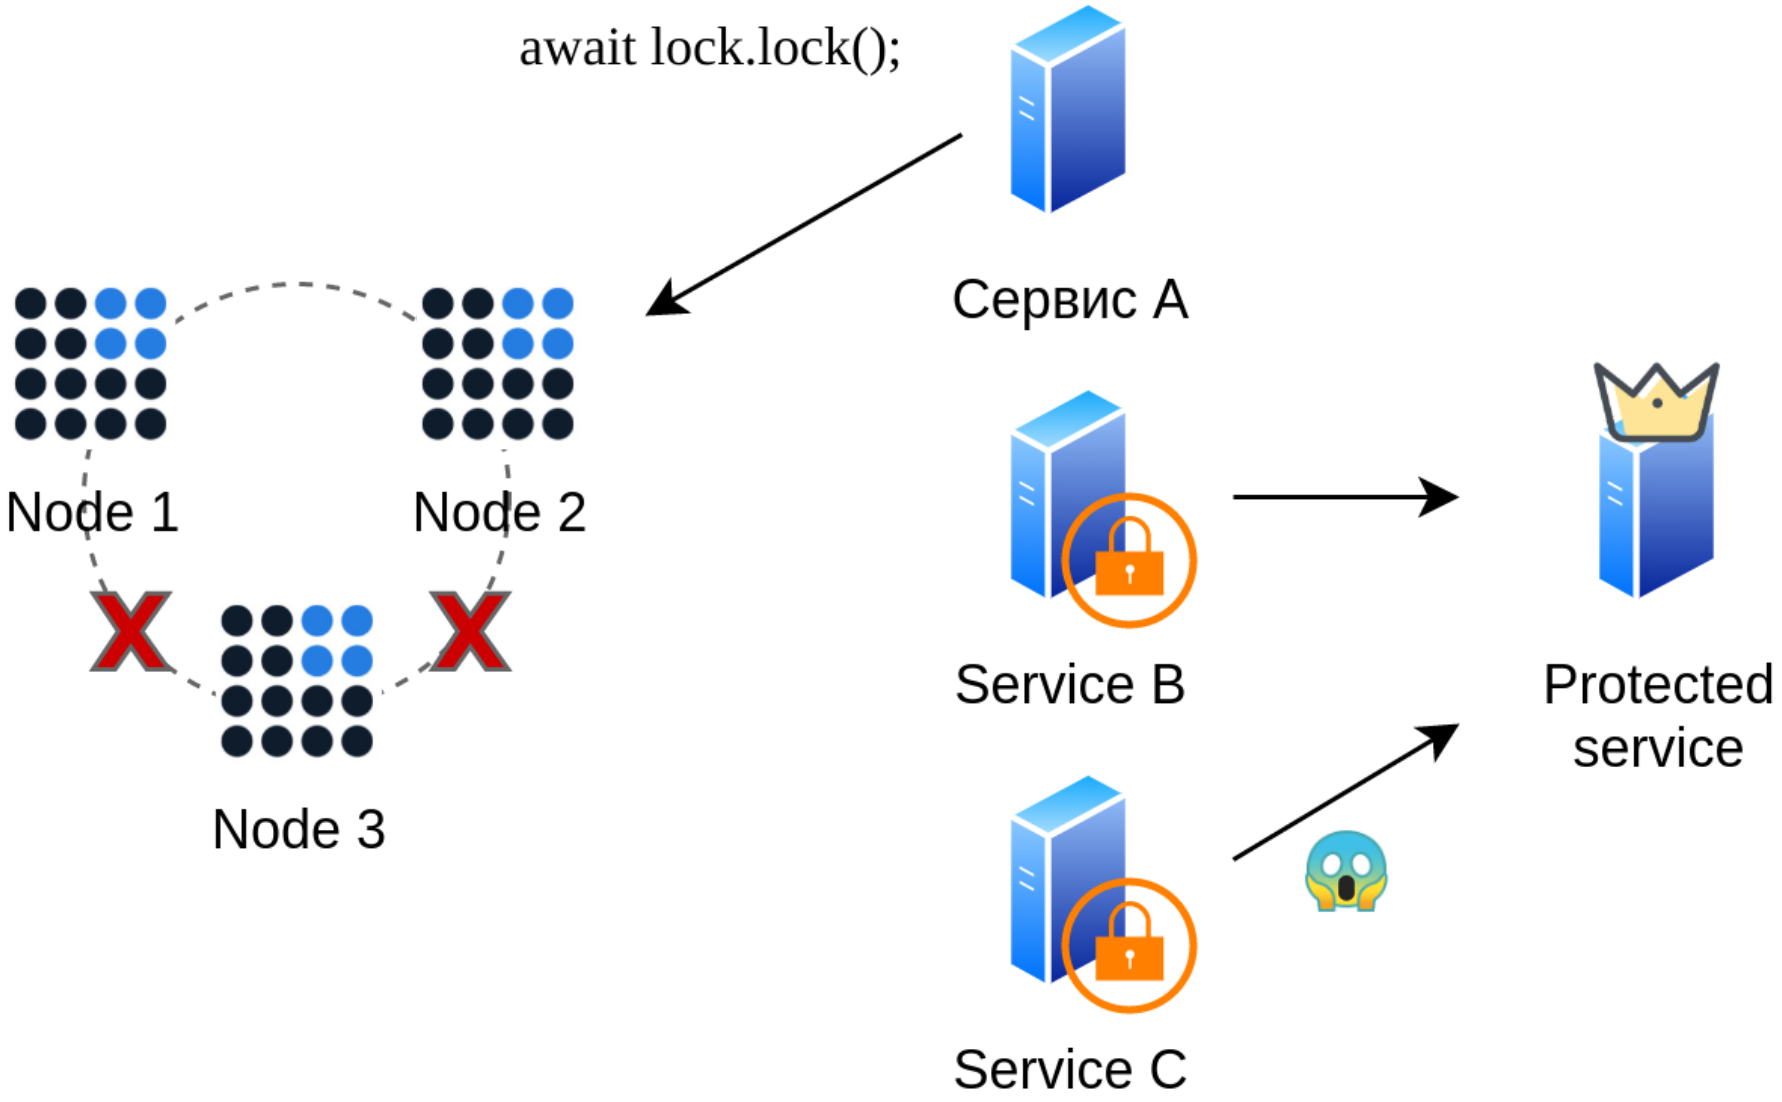

Наш ответ

- С версии 3.12 у нас есть CP Subsystem (т.е. production-ready Raft с Jepsen тестами и lock'ами 🙂)
- https://docs.hazelcast.org/docs/4.0.3/manual/html-single/index.html#cp-subsystem

Новая реализация распределенных lock'ов

```
// У ней внутри Raft
const lock = await client.getCPSubsystem().getLock('my-lock');

const fence = await lock.lock();
try {
    // "защищенный" код
    // (доступен только владельцу)
} finally {
    await lock.unlock(fence);
}
```

P.S. А еще у нас есть Semaphore, AtomicLong и AtomicReference.

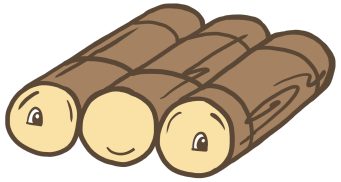

Raft - алгоритм консенсуса, придуманный D.Ongaro и J.Ousterhout (Stanford) в 2013

Некоторые юзкейсы для подобных алгоритмов:

- Хранилище пар ключ-значение
- Распределенные lock'и* (и не только)
- Выбор лидера
- Ограничения на значения полей (например, уникальность)
- Атомарный коммит (распределенные транзакции)

План на сегодня

1. Начинаем пугаться распределенных систем
2. Знакомимся с моделями согласованности
3. CAP теорема и прочие классификации
4. Что за зверь - алгоритм консенсуса?
5. История: Paxos и его подвиды, Raft
6. CASPaxos, как один из недавних Paxos-образных
7. Pet-проект: CASPaxos на Node.js

- **Начинаем пугаться распределенных систем**

Упрощенная до ужаса история

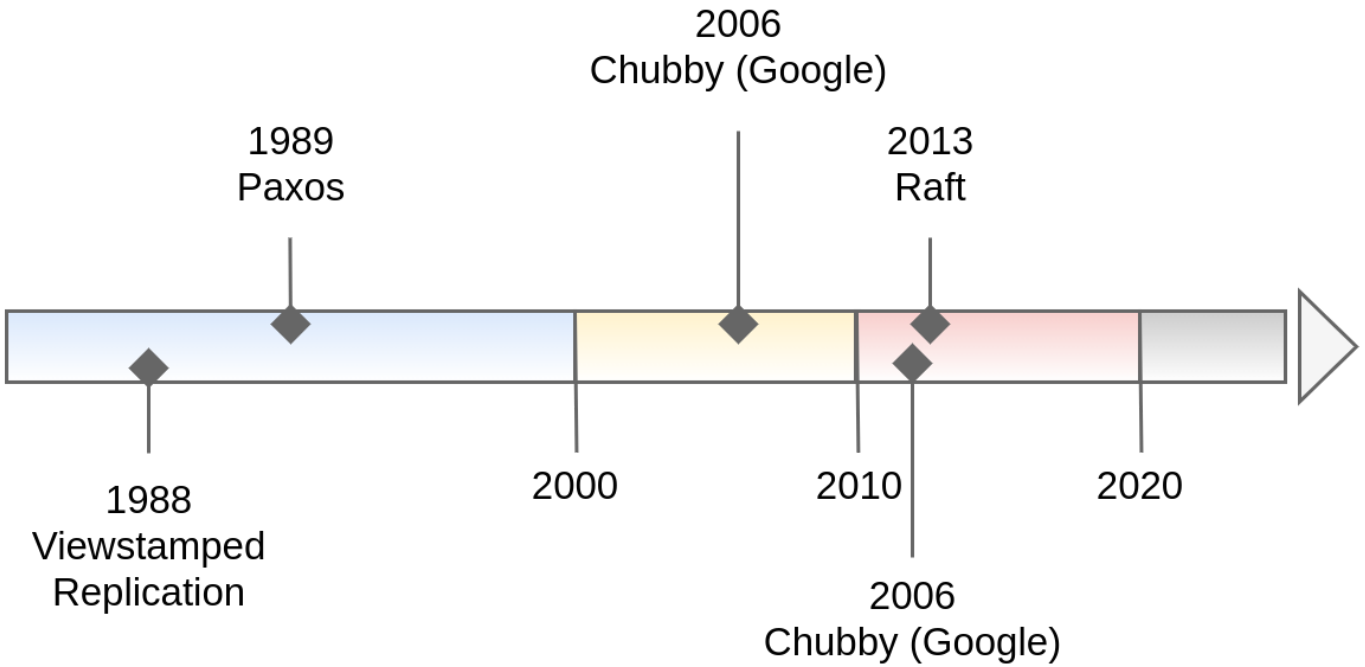

- Эра централизованных БД
- Становление распределенных систем
- Бум распределенных систем
- Будущее?

Распределенная система

- Назовем распределенной систему, хранящую состояние (общее) на нескольких машинах, соединенных сетью
- Для определенности будем подразумевать хранилище пар ключ-значение

Отличия: масштабирование

Централизованная система

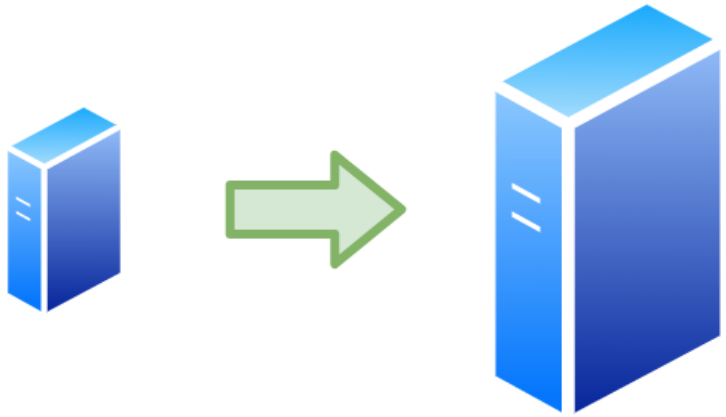

Распределенная система

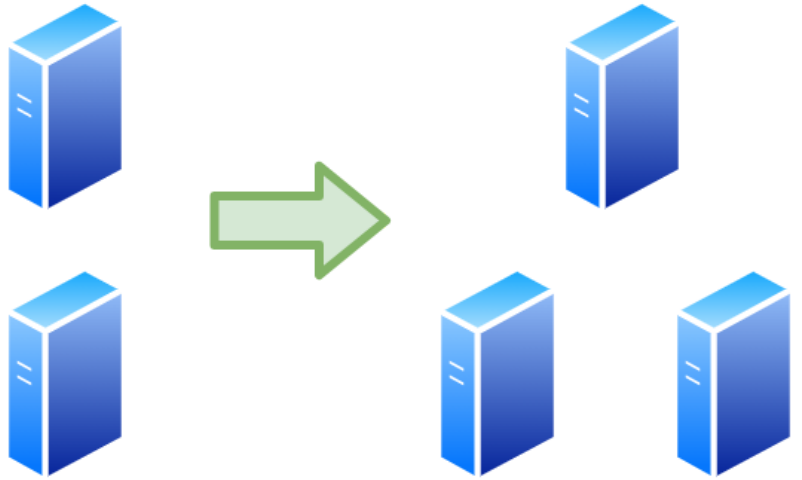

Отличия: работа с данными

Централизованная система

```
const data = await readData();
```

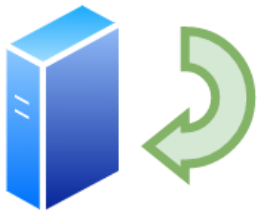

Распределенная система

```
const data = await readData();
```

Отличия: вероятность отказа

Централизованная система

$P(S)$

Распределенная система

$P(S1 + S2) = P(S1) + P(S2) – P(S1 \times S2)$

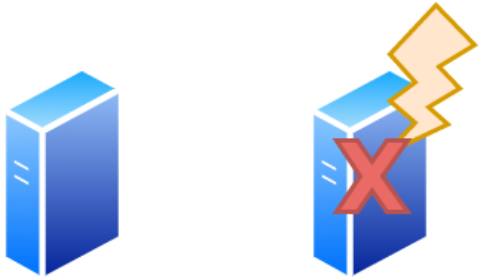

Отличия: критичность отказа

Централизованная система

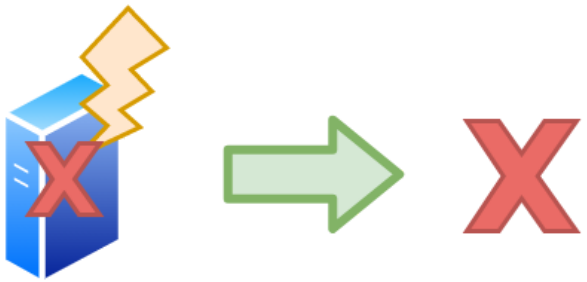

Распределенная система

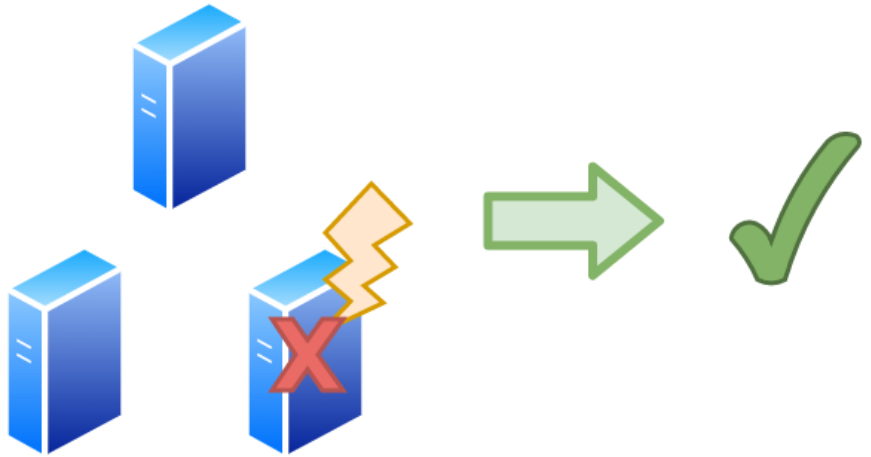

Fallacies of distributed computing

- Инженеры из Sun (R.I.P.) еще в 94м сформулировали такой список:
  - **The network is reliable**
  - **Latency is zero**
  - **Bandwidth is infinite**
  - The network is secure
  - Topology doesn't change
  - There is one administrator
  - Transport cost is zero
  - The network is homogeneous
- P.S. Добавим сюда "**Clocks are in sync**"

Сеть 🌐

- Мы работаем с асинхронными сетями
- Отправленный запрос может:
  - Быть потерян при отправке туда/обратно
  - Находиться в очереди ожидания отправки (если сеть под нагрузкой)
  - Быть получен, но машина-адресат дала сбой до или во время обработки
- Единственный способ подтверждения - получить ответ

Локальные 🕐

- Каждая машина работает с локальным временем (`Date.now()`)
- Локальные монотонные часы (`process.hrtime`) помогают, но далеко не всегда
- В действительности нам хотелось бы иметь глобальные часы

Глобальные 🕐

- Увы, глобальные (синхронизированные) часы невозможны без специального железа
- Байка: в Google Spanner часы в ЦОД синхронизированы в пределах 7 мс (атомные часы + GPS)
- Оффтопик: векторные "часы" частично решают проблему

Чего мы ждем от распределенной системы? 🤔

Мой личный список

1. Отказоустойчивость
2. Масштабируемость
3. Удобство поддержки (мониторинг, администрирование)

Чего мы еще ждем?

- Допустим, что мы ждем того же поведения, что и у централизованного хранилища
- А именно - с клиентской стороны поведение должно быть, как если бы это была централизованная система (пока остановимся на этой формулировке)

Фигня вопрос - сейчас придумаем алгоритм

1. Любой узел принимает клиентские запросы (прочитать/записать)
2. Затем - отправляет операцию на все остальные узлы
3. Ждет ответов от большинства (консенсус жеж 😄)
4. Дождавшись консенсуса, отправляет клиенту сообщение об успехе

Что не так с нашим изобретением?

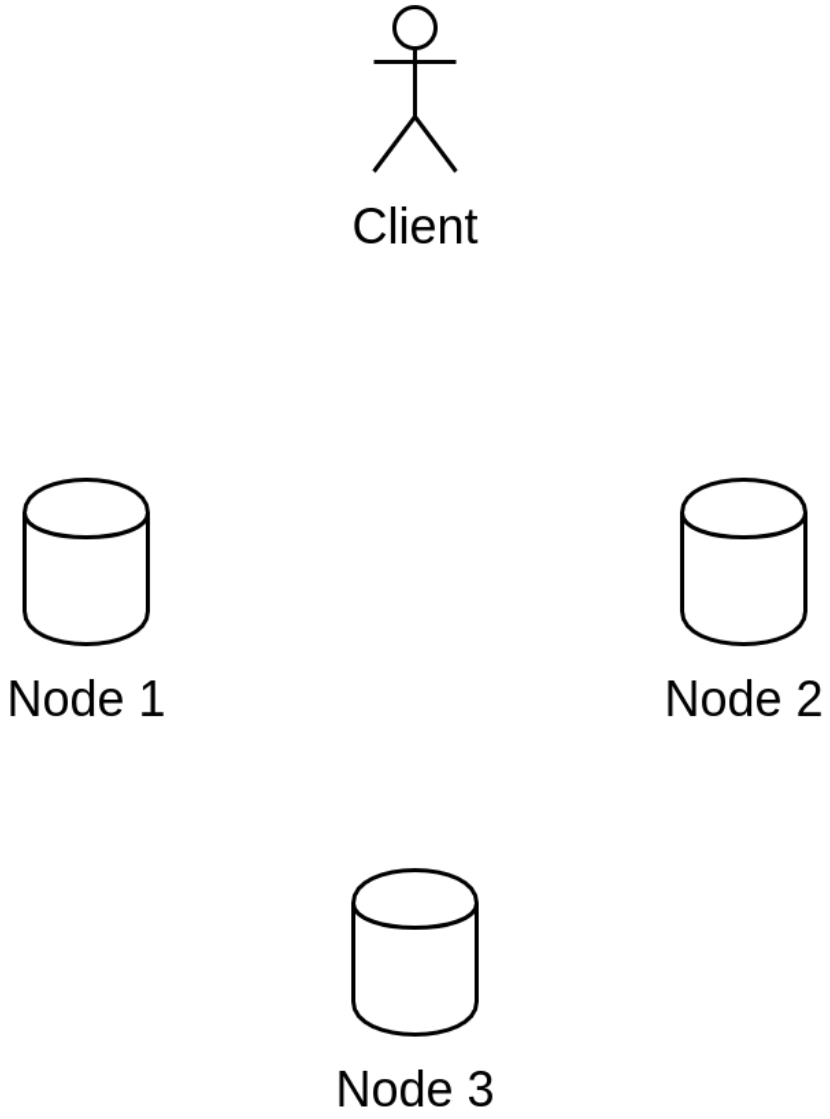

Что не так с нашим изобретением?

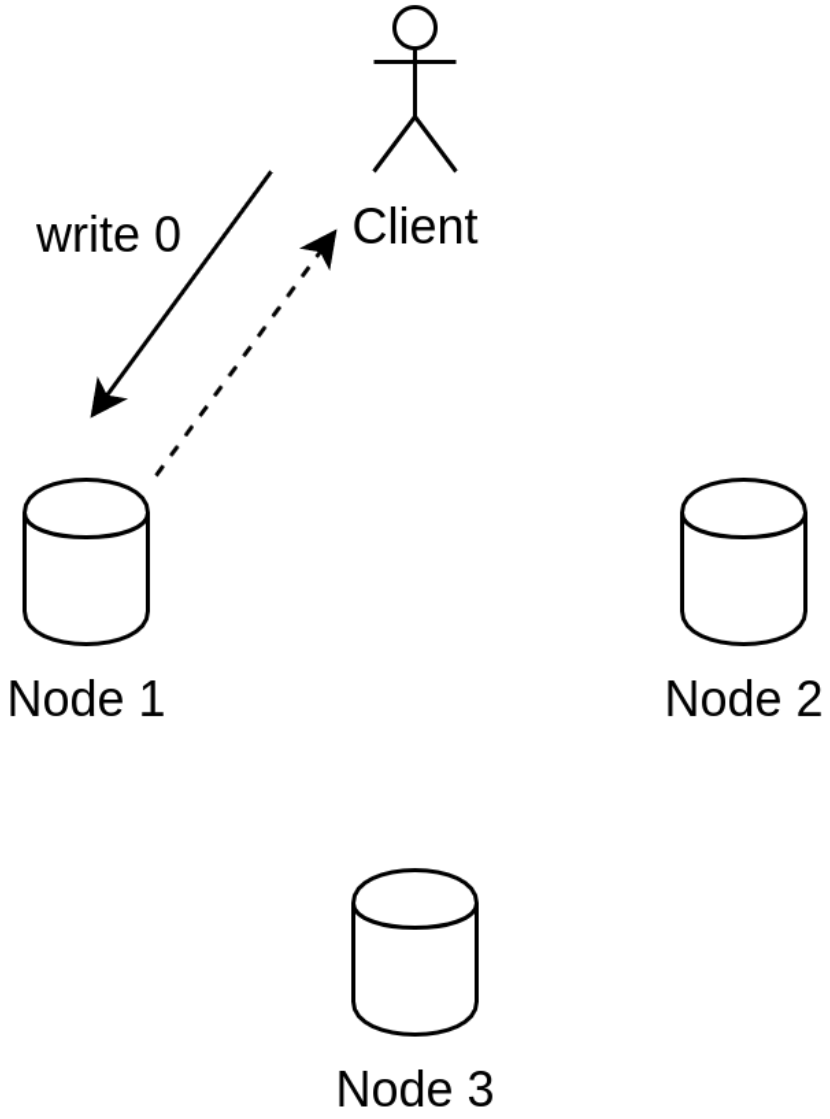

Что не так с нашим изобретением?

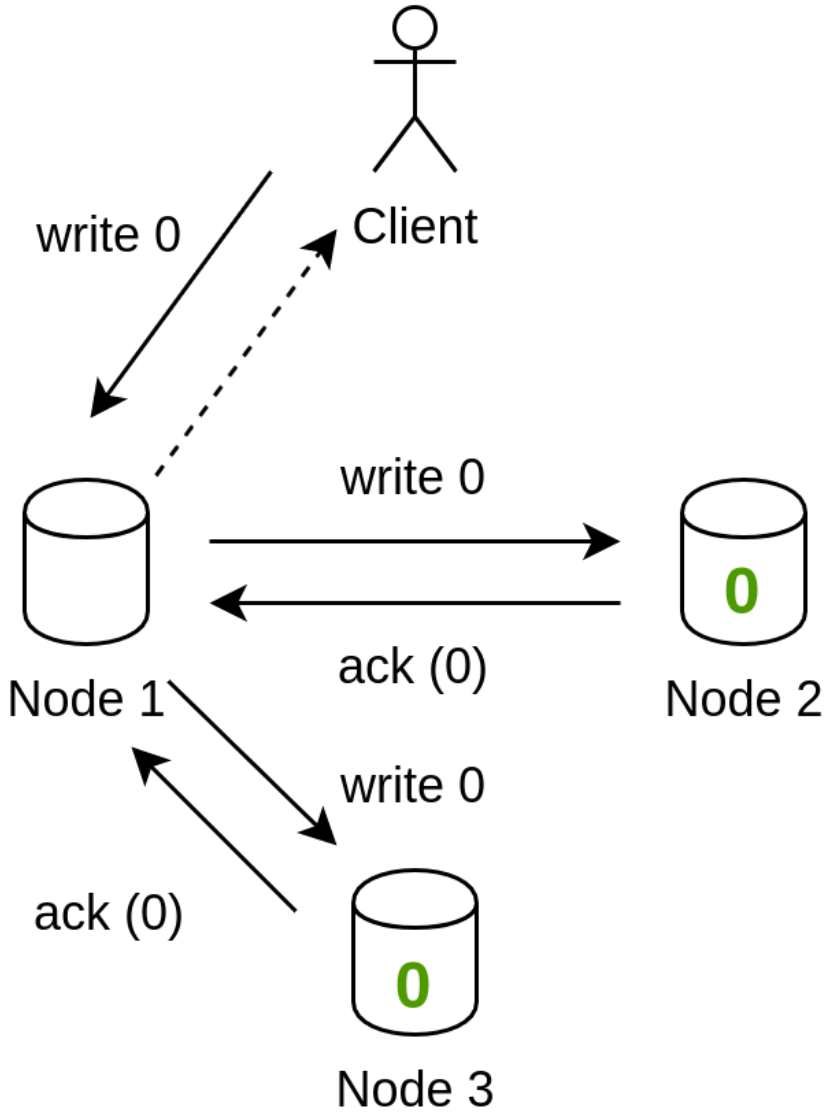

Что не так с нашим изобретением?

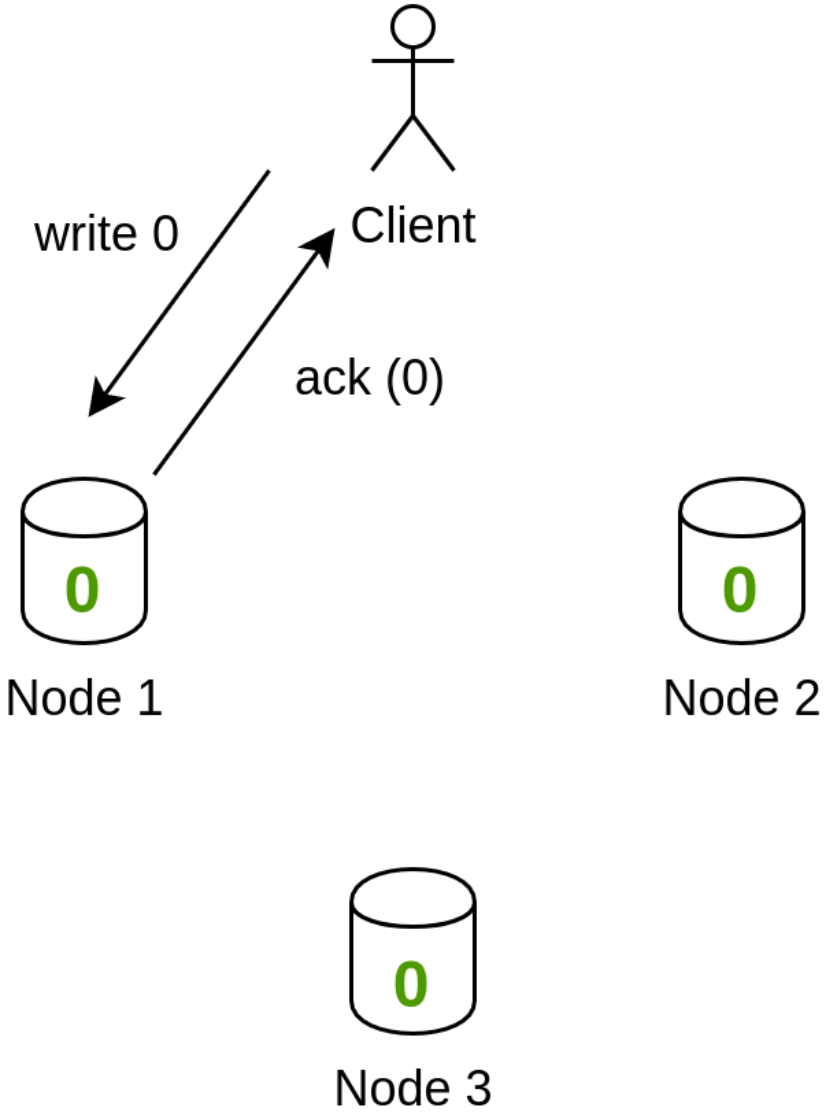

Что не так с нашим изобретением?

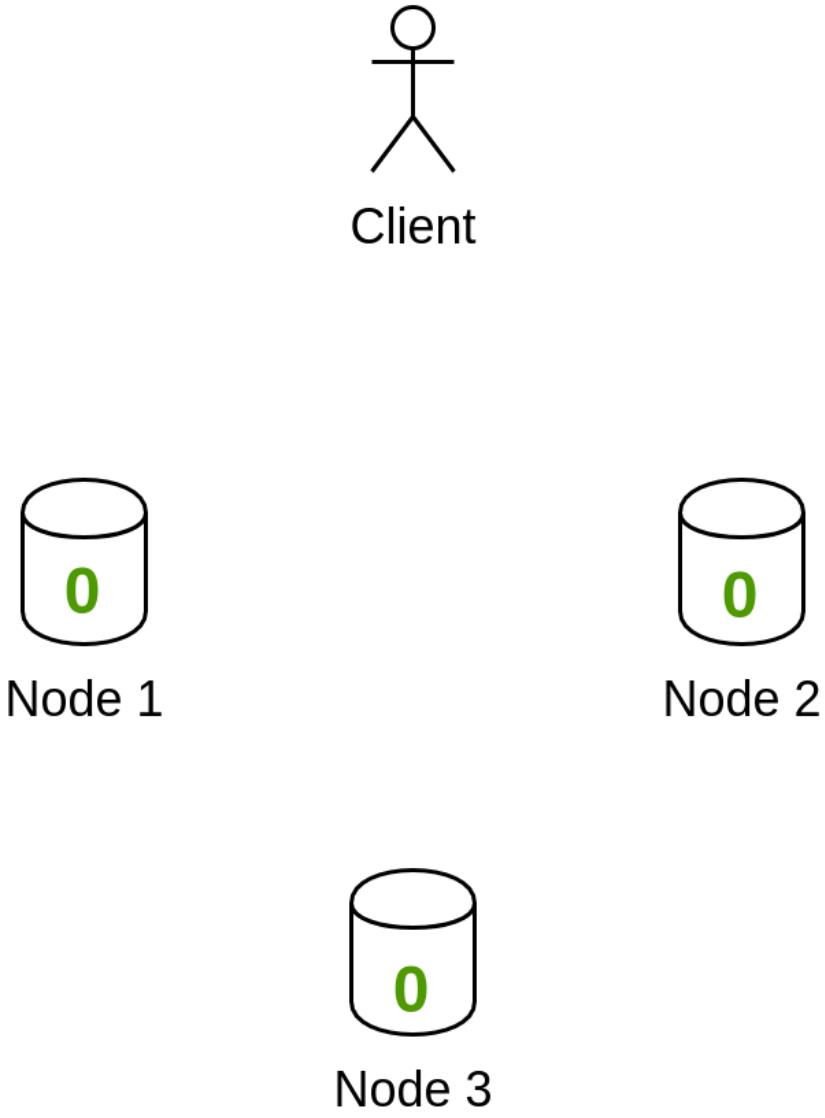

Что не так с нашим изобретением?

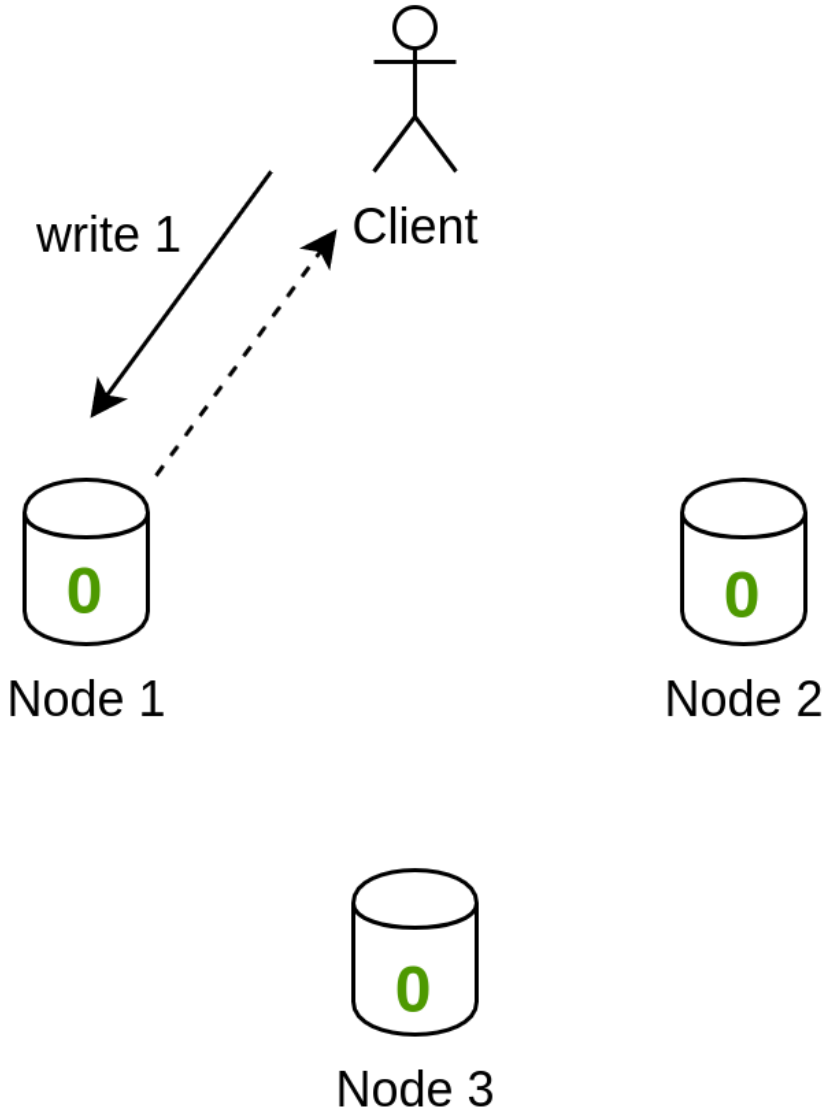

Что не так с нашим изобретением?

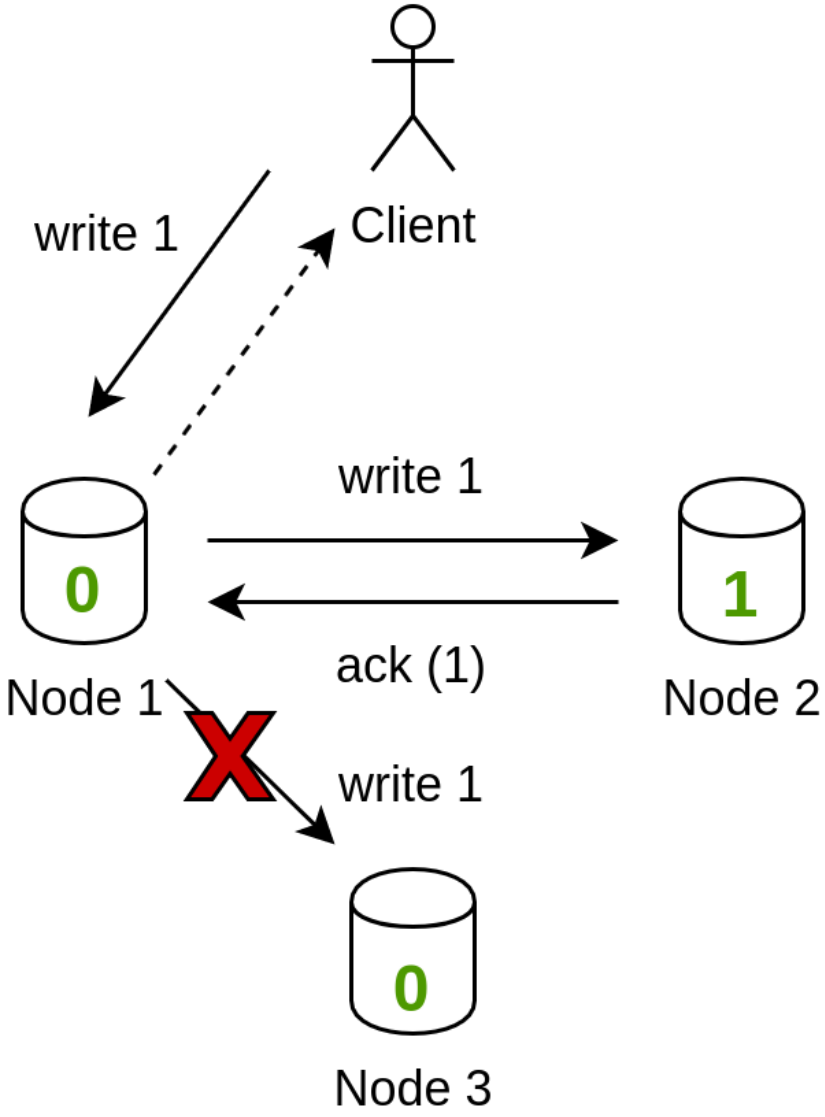

Что не так с нашим изобретением?

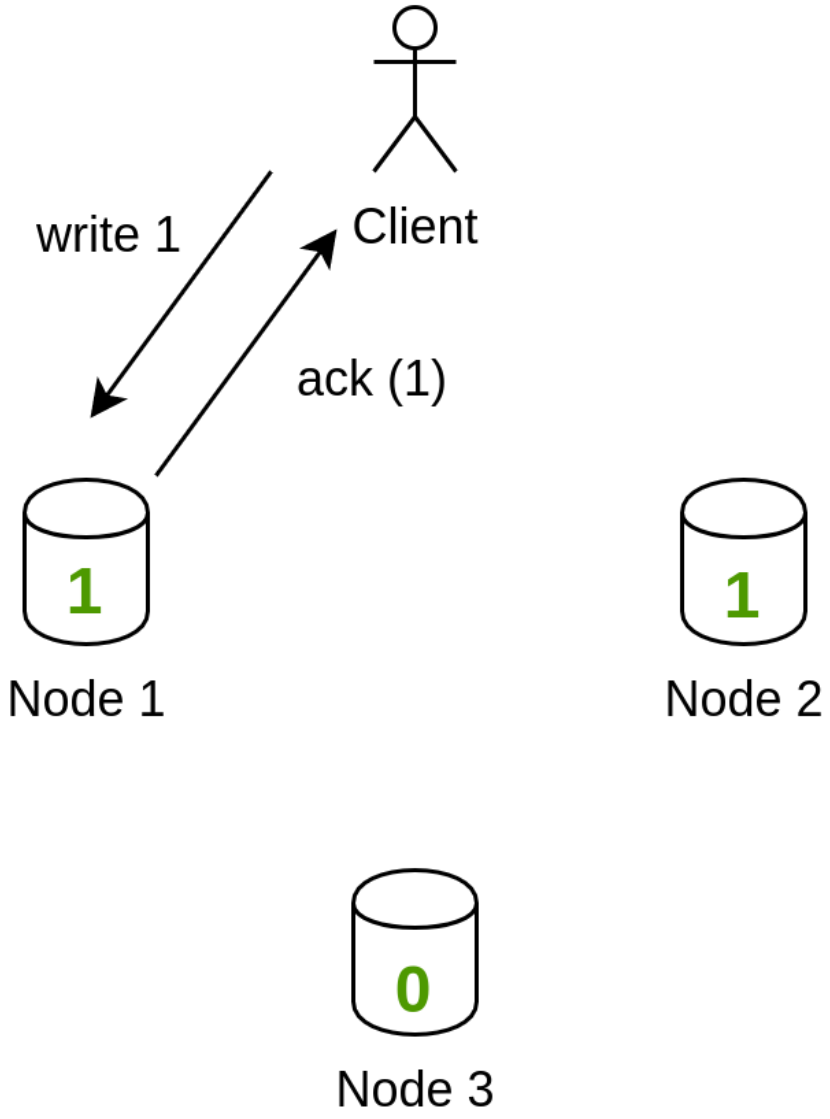

Что не так с нашим изобретением?

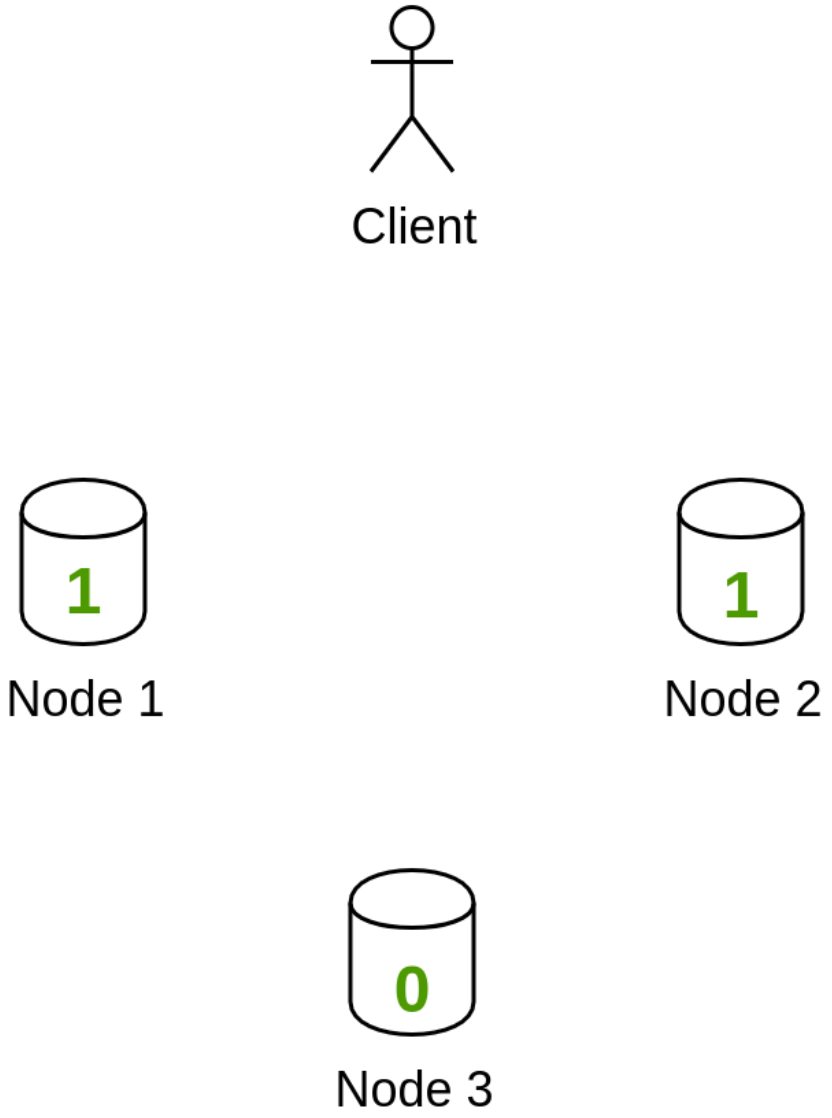

Что не так с нашим изобретением?

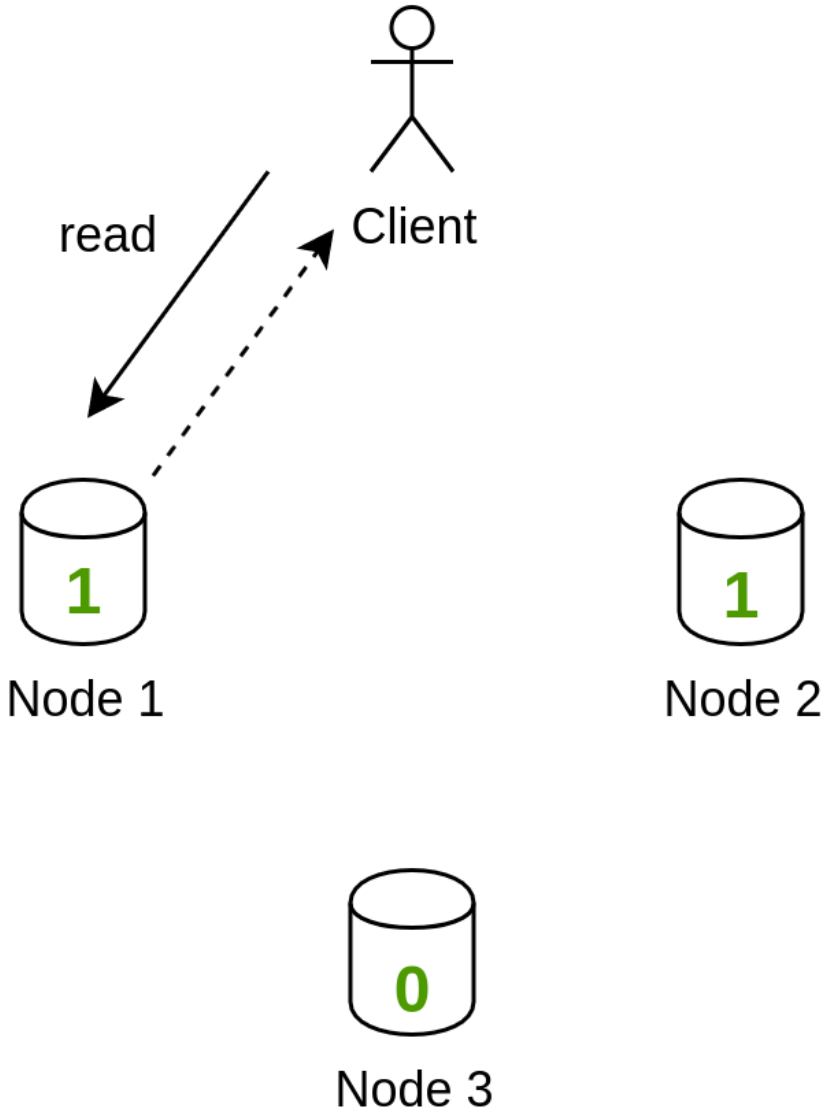

Что не так с нашим изобретением?

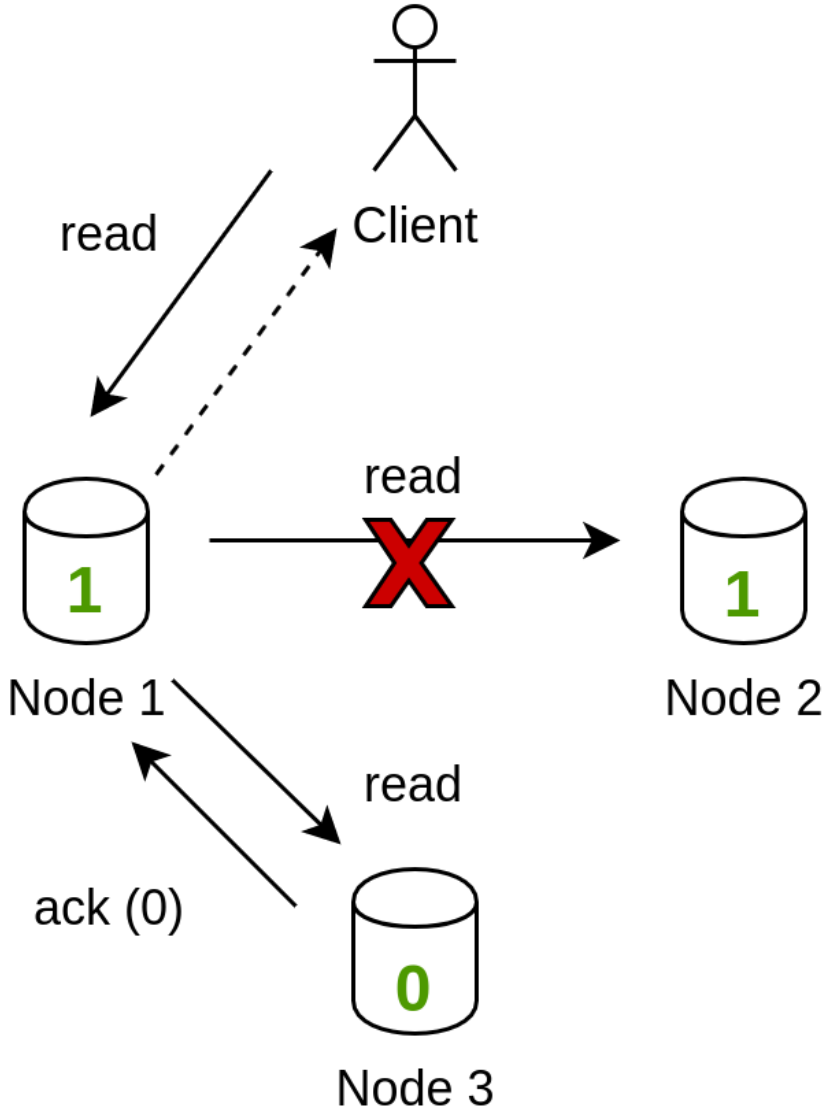

Что не так с нашим изобретением?

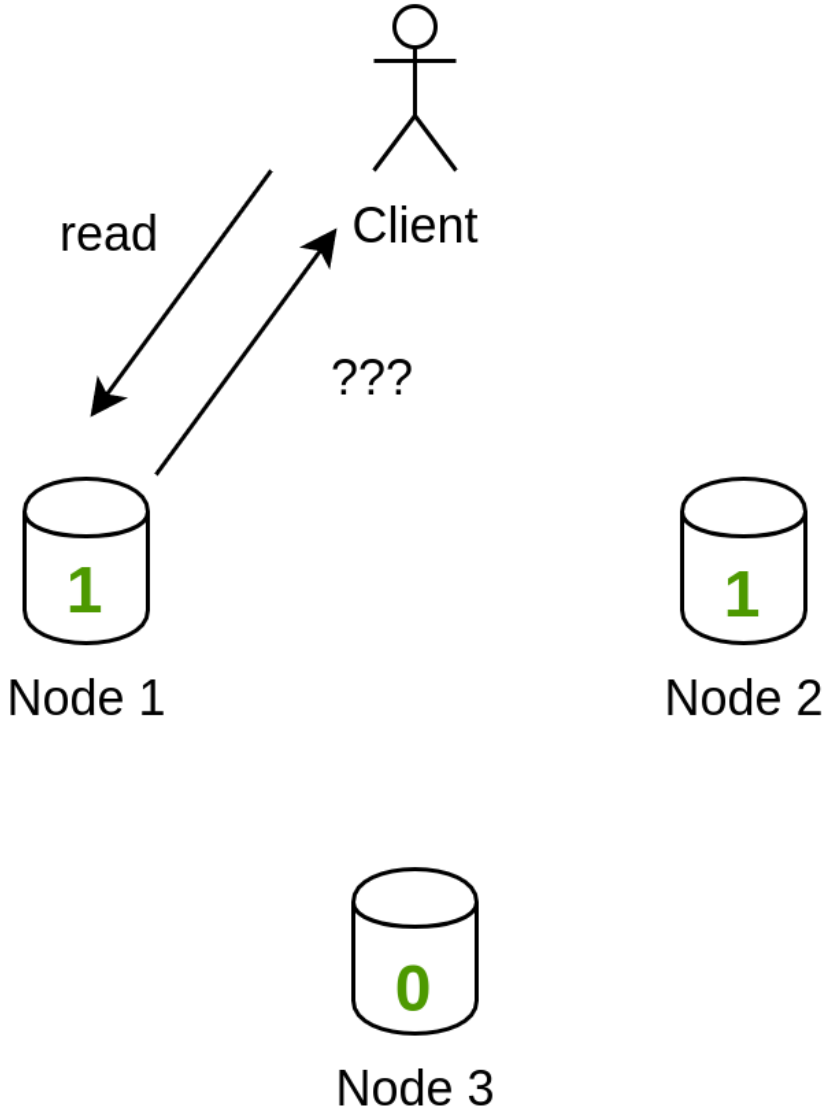

Промежуточные выводы 🤔

- Распределенные системы существенно отличаются от централизованных
- Нам не удалось с ходу придумать хороший алгоритм для распределенного хранилища

- **Знакомимся с моделями согласованности**

Неформальное определение

Модель согласованности (consistency model) - это гарантии, которые система (внезапно, не только распределенная) предоставляет относительно набора поддерживаемых операций

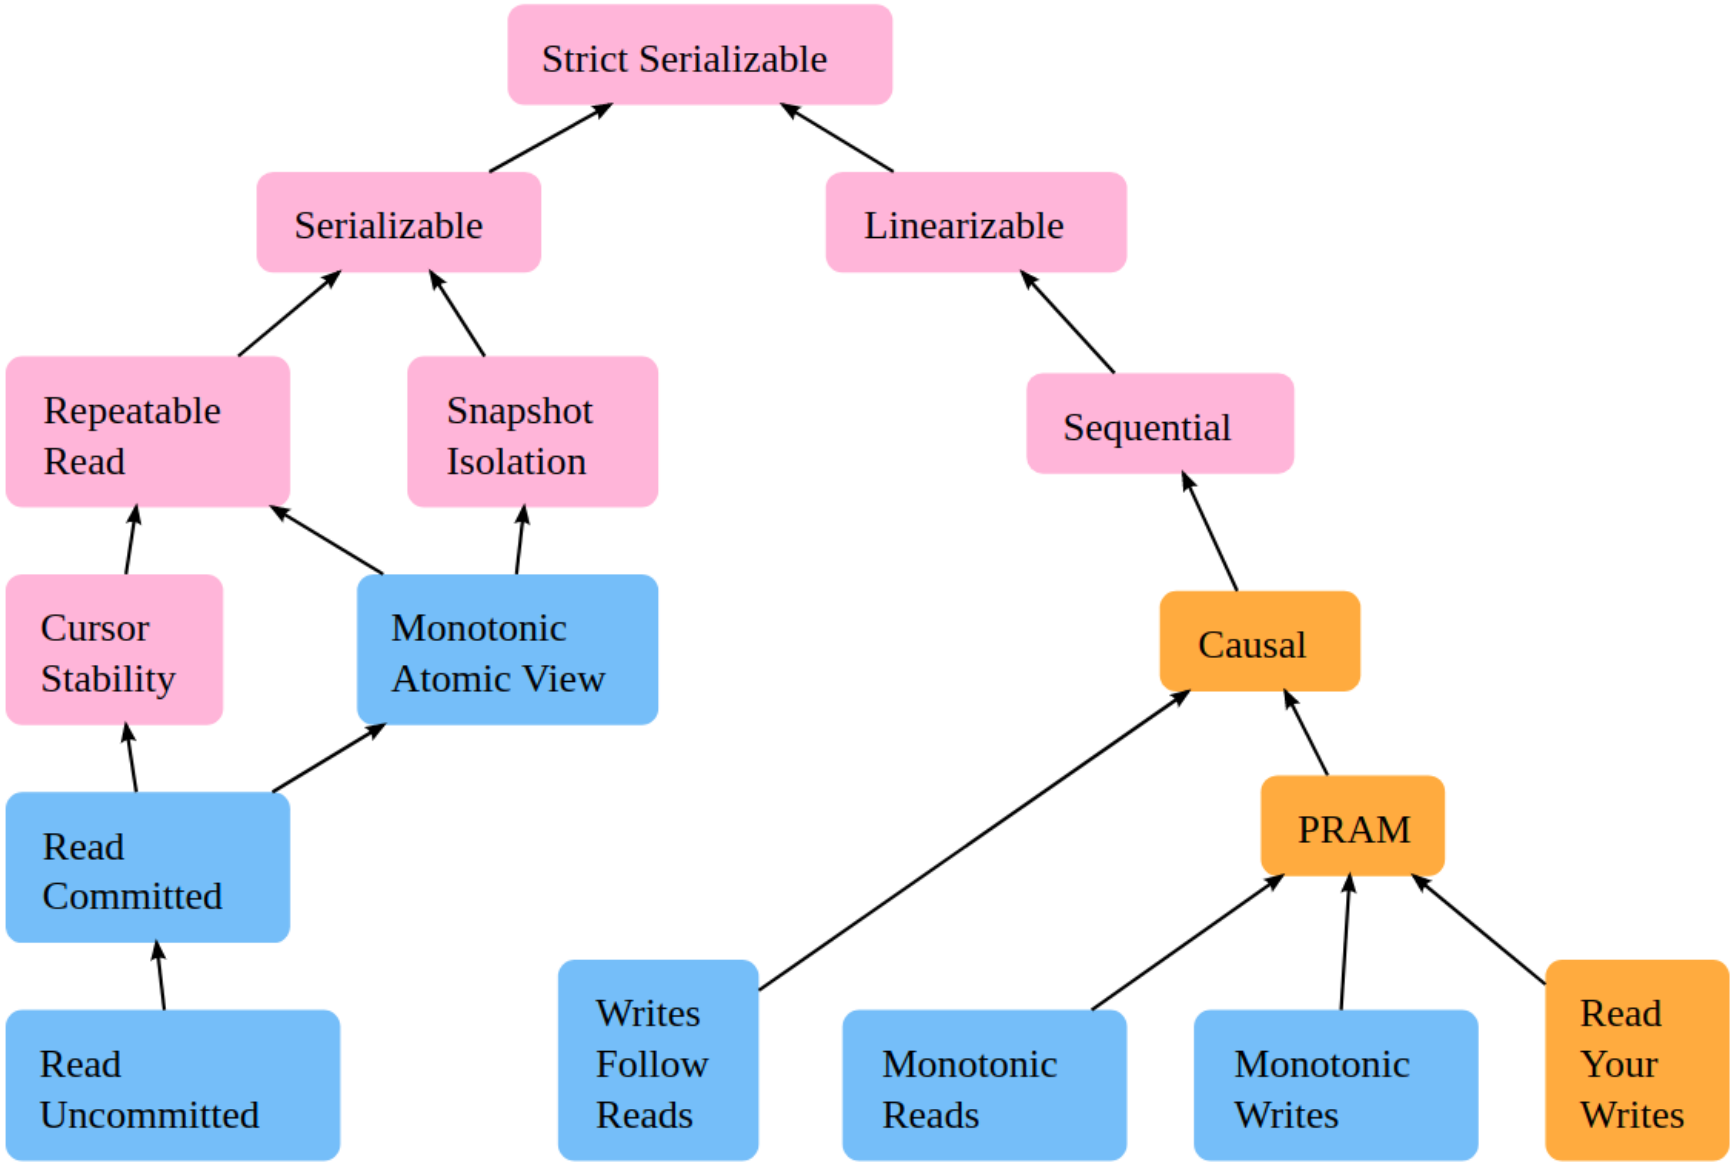

Source: https://jepsen.io/consistency

Linearizable consistency model

- Одна из наиболее строгих (сильных) моделей согласованности для **одного** объекта
- Именно ее мы и подразумевали (надеюсь) ранее:
  "с клиентской стороны поведение должно быть, как если бы это была централизованная система"

Неформальное определение модели

Система гарантирует, что каждая операция выполняется атомарно, в **некотором** (общем для всех клиентов) **порядке**, не противоречащим порядку выполнения операций в реальном времени.

Т.е. если операция A завершается до начала операции B, то B должна учитывать результат выполнения операции A.

Допустимый порядок

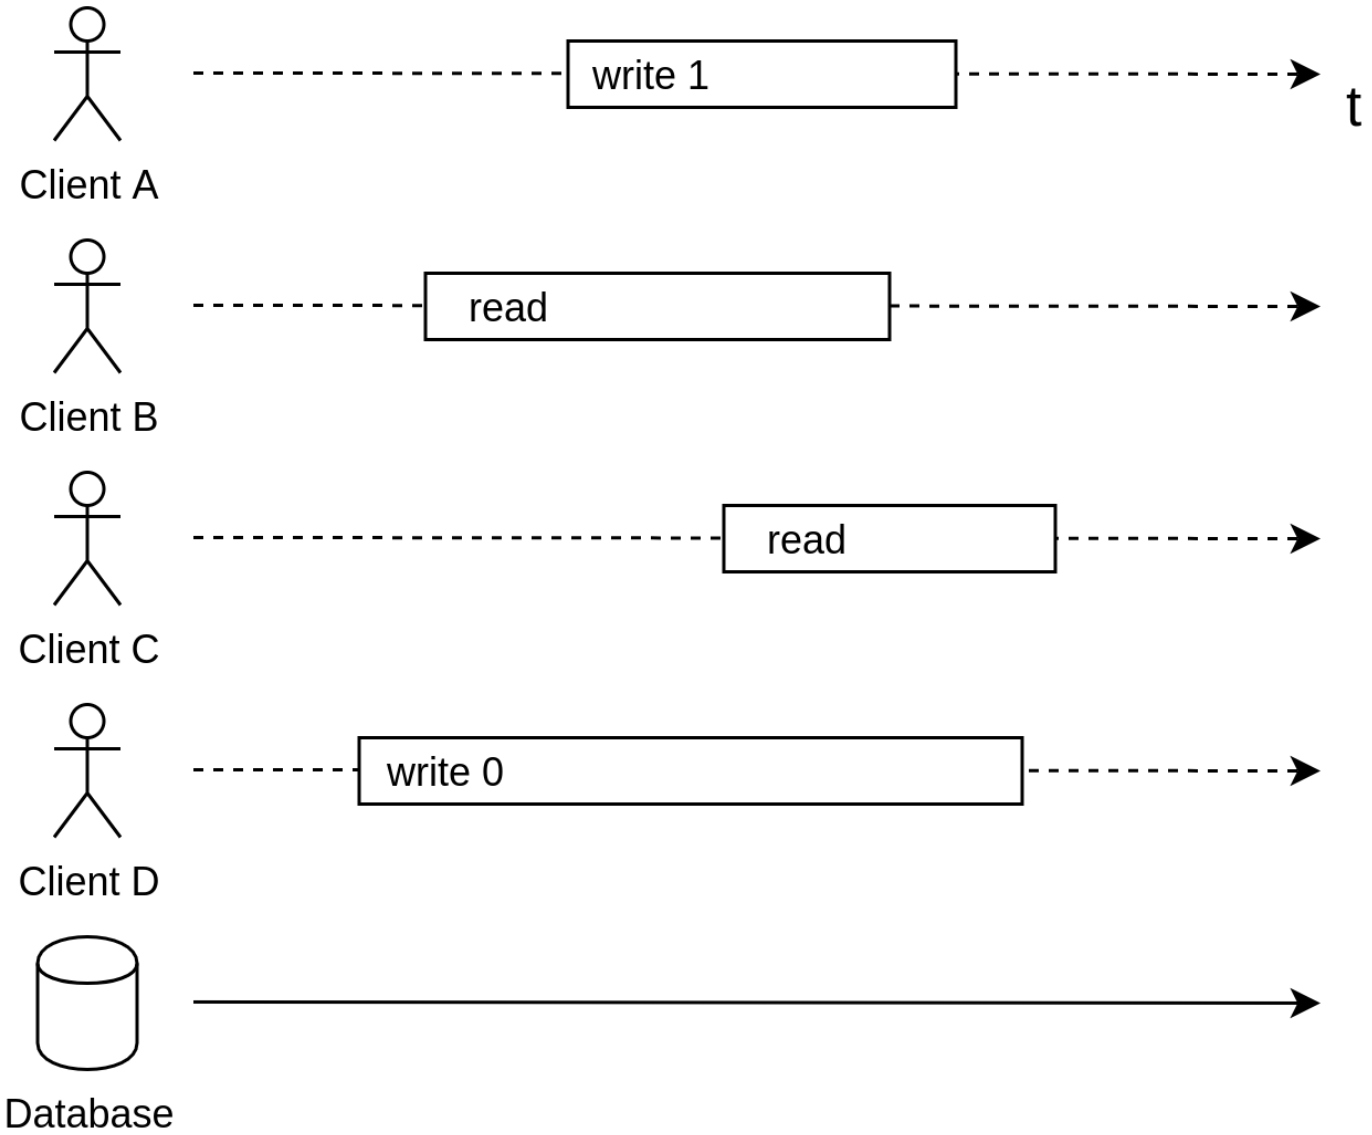

Допустимый порядок

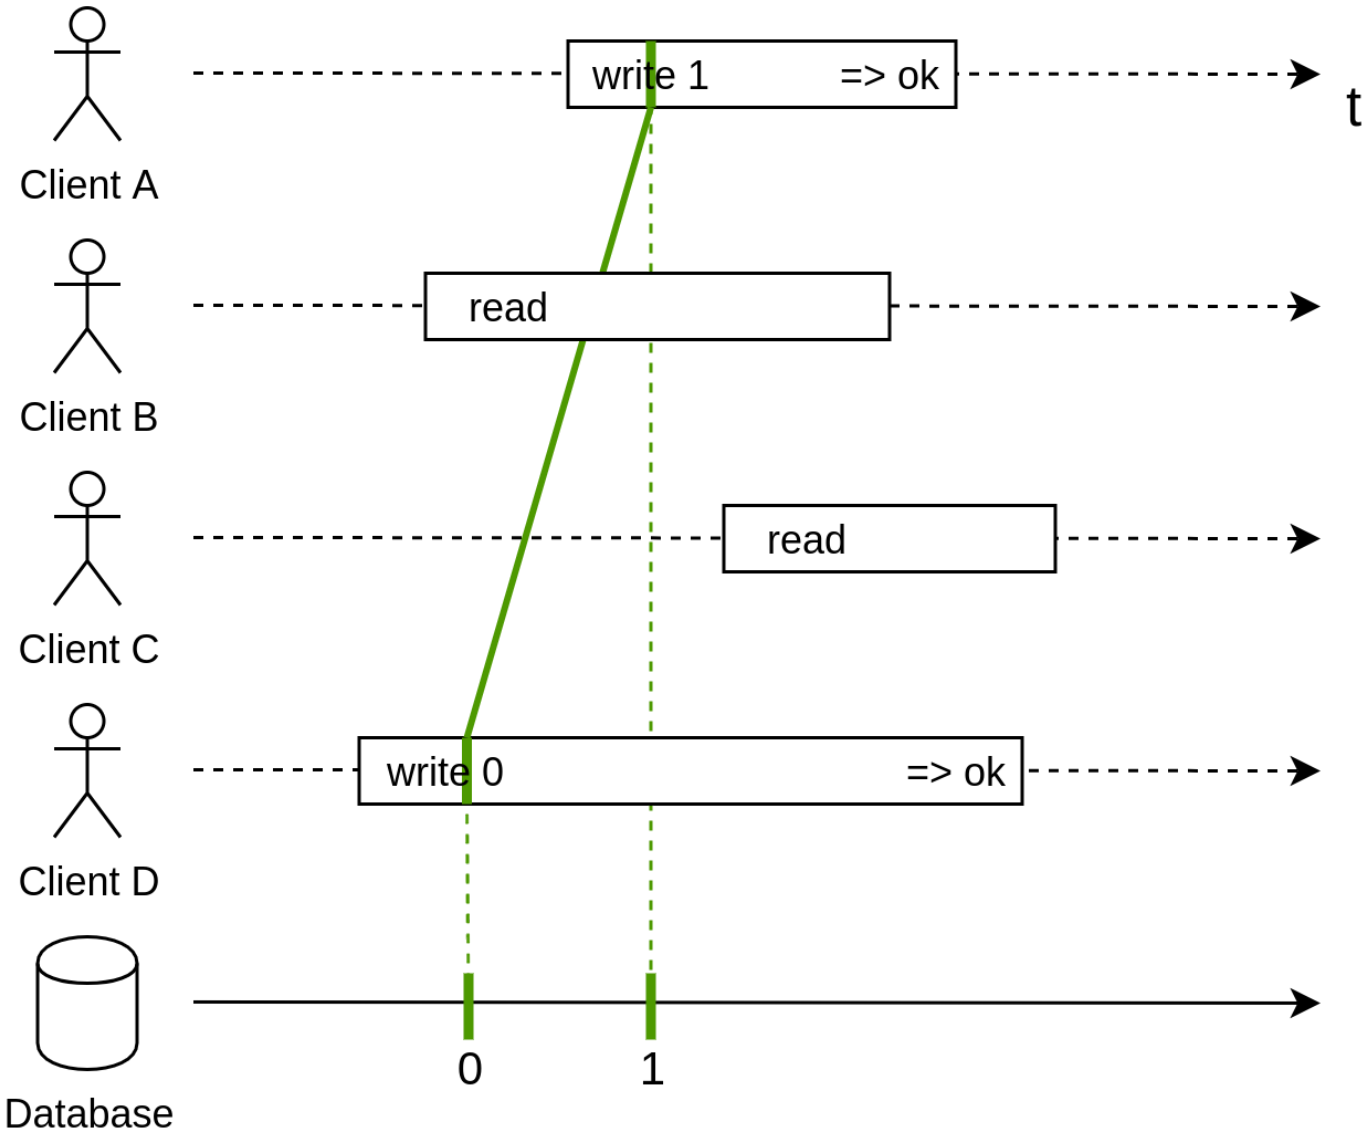

Допустимый порядок

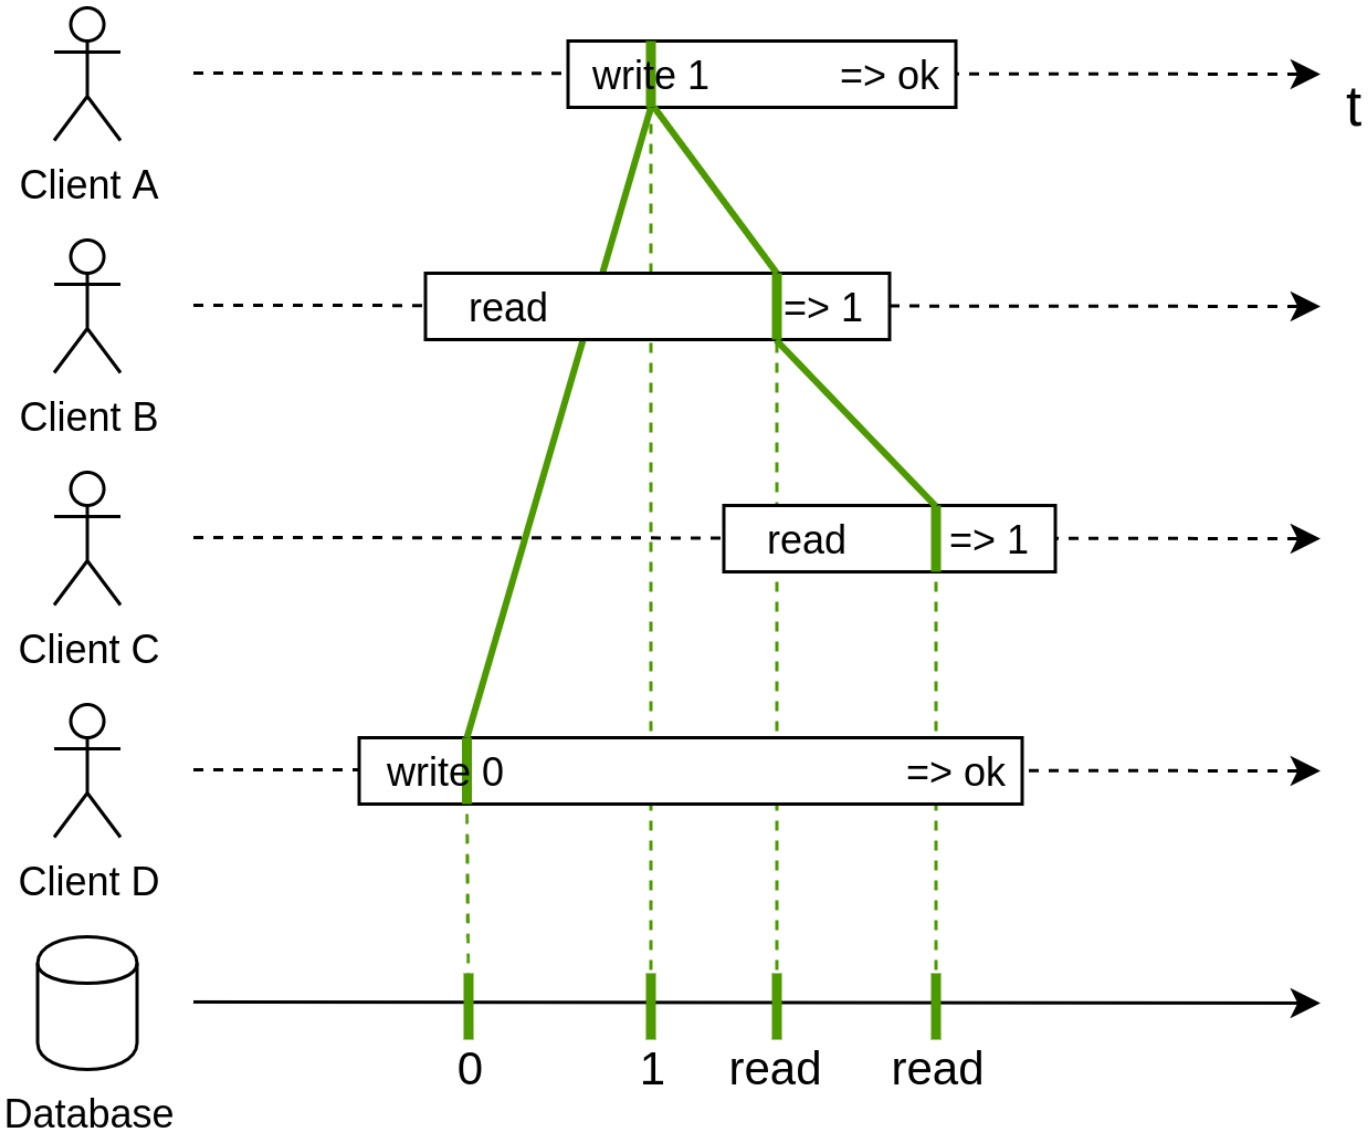

Недопустимый порядок

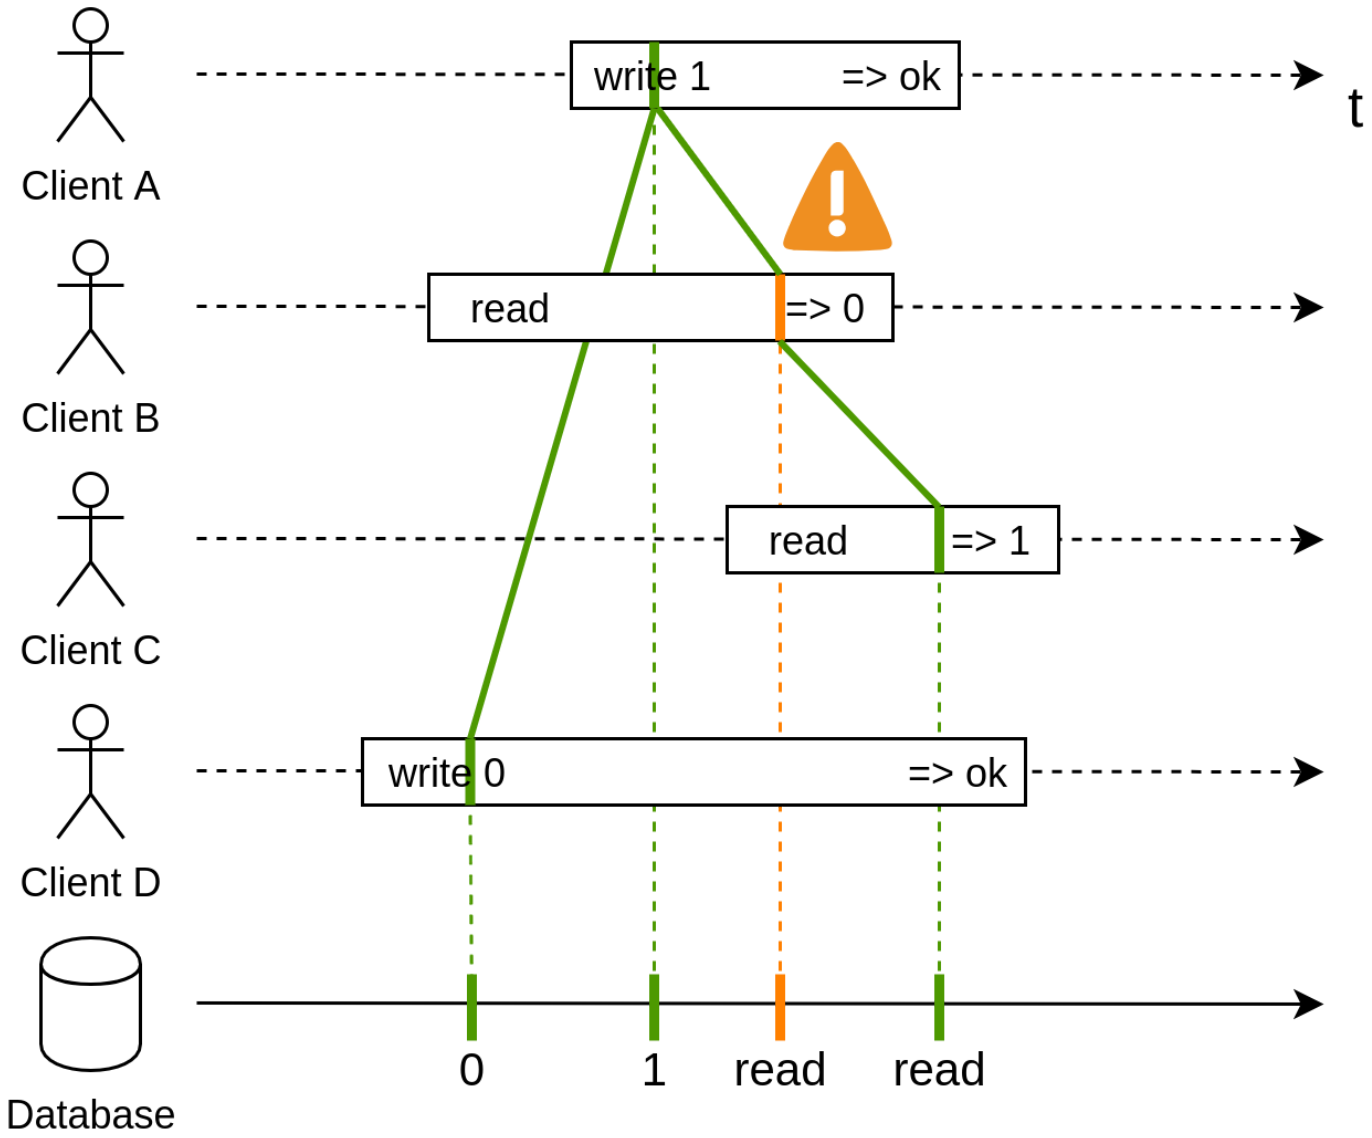

Промежуточные выводы 🤔

- Моделей согласованности много
- Многие из них связаны понятием строгости
- Серебряной пули нет

- CAP теорема и прочие классификации

CAP теорема

- Сформулирована Eric Brewer в 1998, как утверждение
- В 2002 появилось формальное доказательство
- CAP:
  - Consistency: подразумевается линеаризуемость
  - Availability: каждый запрос, полученный узлом системы, должен приводить к ожидаемому ответу (не к ошибке)
  - Partition tolerance: подразумевается коммуникация через асинхронную сеть

Partition tolerance

Network partition - сценарий, когда узлы продолжают функционировать, но некоторые из них не могут общаться между собой

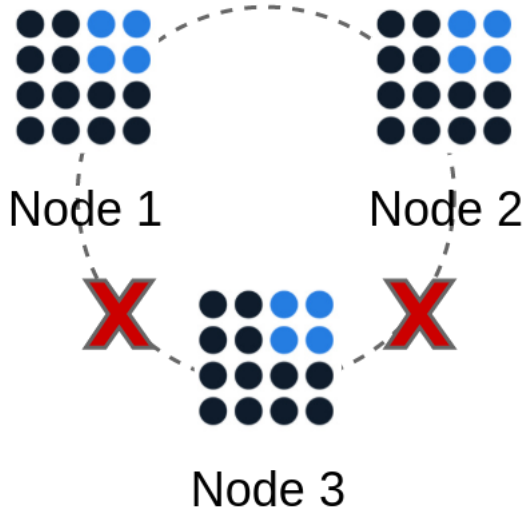

Неформальное определение

В условиях network partition рассматриваемая система может быть:

- Доступна (AP)
- Согласована (CP)

P.S. CA опции в CAP теореме нет и в помине

Критика

- Однобокая классификация, которая почему-то прижилась
- Например, РСУБД с одной read-only репликой не является ни CP, ни AP
- Теорема ничего не говорит о времени отклика системы, т.е. AP система может отвечать сколь угодно медленно
- Наконец, network partition - далеко не единственный сценарий отказа

Альтернативы

- PACELC теорема - расширение CAP теоремы (Daniel J. Abadi, 2010)
- PAC = PA | PC (та же CAP теорема)
- ELC = EL | EC:
  - E: else
  - L: latency
  - C: consistency

Промежуточные выводы 🤔

- Классификации позволяют рассуждать об общих чертах поведения
- Системы из одного и того же класса могут существенно отличаться

- Что за зверь - алгоритм консенсуса?

Неформальное определение

- Алгоритм консенсуса - алгоритм, позволяющий узлам системы достигнуть консенсус, т.е. принять совместное решение **о том или ином** действии
- Под действием часто понимают **однократное** изменение регистра (Paxos)
- С точки зрения отказов рассматривают только non-Byzantine faults

P.S. А еще есть "скандальный" FLP result (1985)

Связь с linearizability

- На практике консенсус нужен на **последовательности** действий
- Поэтому для реализаций встречается определение atomic broadcast (total order broadcast) - консенсус тут нужен для принятия решения о следующем действии
- Можно показать, что linearizability и total order broadcast можно свести друг к другу
- А значит, мы говорим о CP системах, с точки зрения CAP теоремы

Краткий список алгоритмов консенсуса

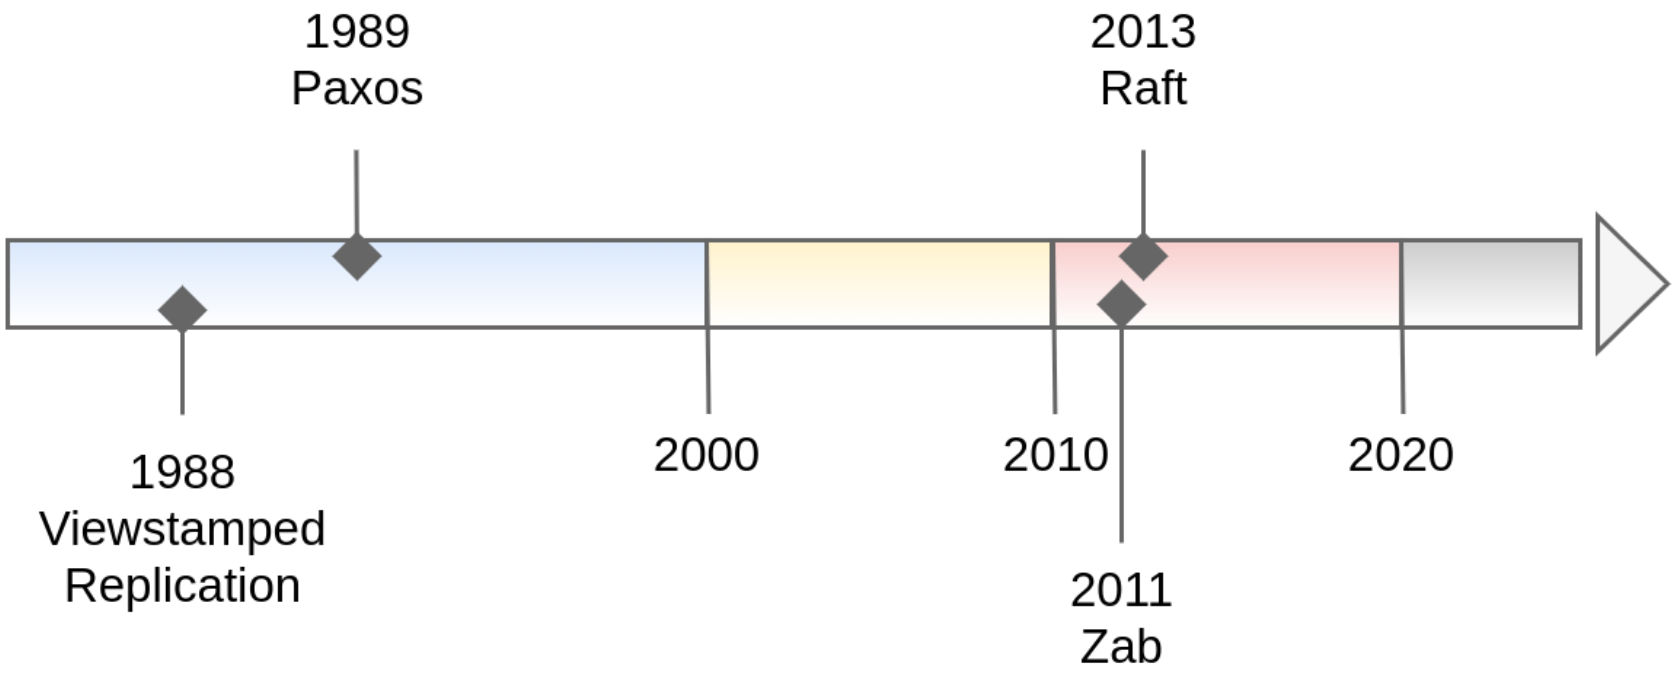

Paxos и его подвиды: Chubby, Spanner

Raft: Consul, etcd, Hazelcast, RethinkDB, TiKV и т.д.

Zab: ZooKeeper

Верификация корректности: теория

- TLA+ (L.Lamport)
- Язык для моделирования программ и систем, распределенных и не только

```
EXTENDS TLC

(* --algorithm hello_world
variable s \in {"Hello", "World!"};
begin
  A:
    print s;
end algorithm; *)
```

Верификация корректности: практика

- Jepsen (K.Kingsbury a.k.a. aphyr)

```
INFO  jepsen.core - Analysis invalid! (ﾉಥ益ಥ）ﾉ ┻━┻
```

Темная сторона алгоритмов консенсуса (。▼皿▼)

- Производительность напрямую зависит от задержек сети
- Высокая сложность реализации и верификации
- Для работы кластера требуется строгое большинство узлов

- История: Paxos и его подвиды, Raft

Vanilla Paxos

- Paxos (1998) - p2p (leaderless)
- В основе - Synod/Single-Decree Paxos
- Позволяет принять строго одно решение (о значении регистра)
- Часто под Paxos подразумевают семейство алгоритмов

Подвиды Paxos

- Multipaxos (2001)
- FastPaxos (2004~2005)
- Generalized Paxos (2004~2005)
- Mencius (2008)
- Multicoordinated Paxos (2006)
- Vertical Paxos (2009)
- Ring Paxos (2010) / Multi-Ring Paxos (2010)
- SPaxos (2012) / EPaxos (2013) / FPaxos (2016) / KPaxos (2017) / WPaxos (2017)
- **CASPaxos** (2018)
- SDPaxos (2018)

Raft

- Raft (2013) - single leader, replicated log
- Время делится на периоды (term), каждый из которых начинается в выбора лидера
- Упор сделан на простоту понимания алгоритма
- https://raft.github.io

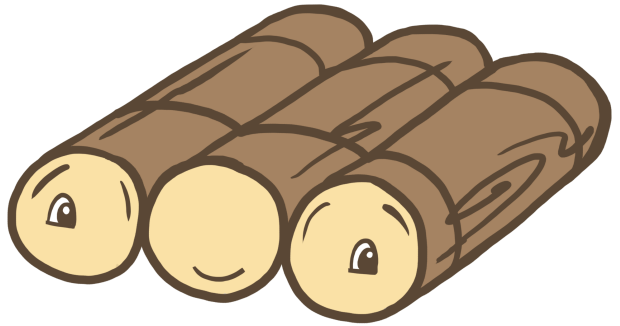

Промежуточные выводы 🤔

- Алгоритмов консенсуса довольно много
- И алгоритм, и реализацию стоит верифицировать
- Не стоит пытаться решить любую проблему через консенсус

- **CASPaxos, как один из недавних Paxos-образных**

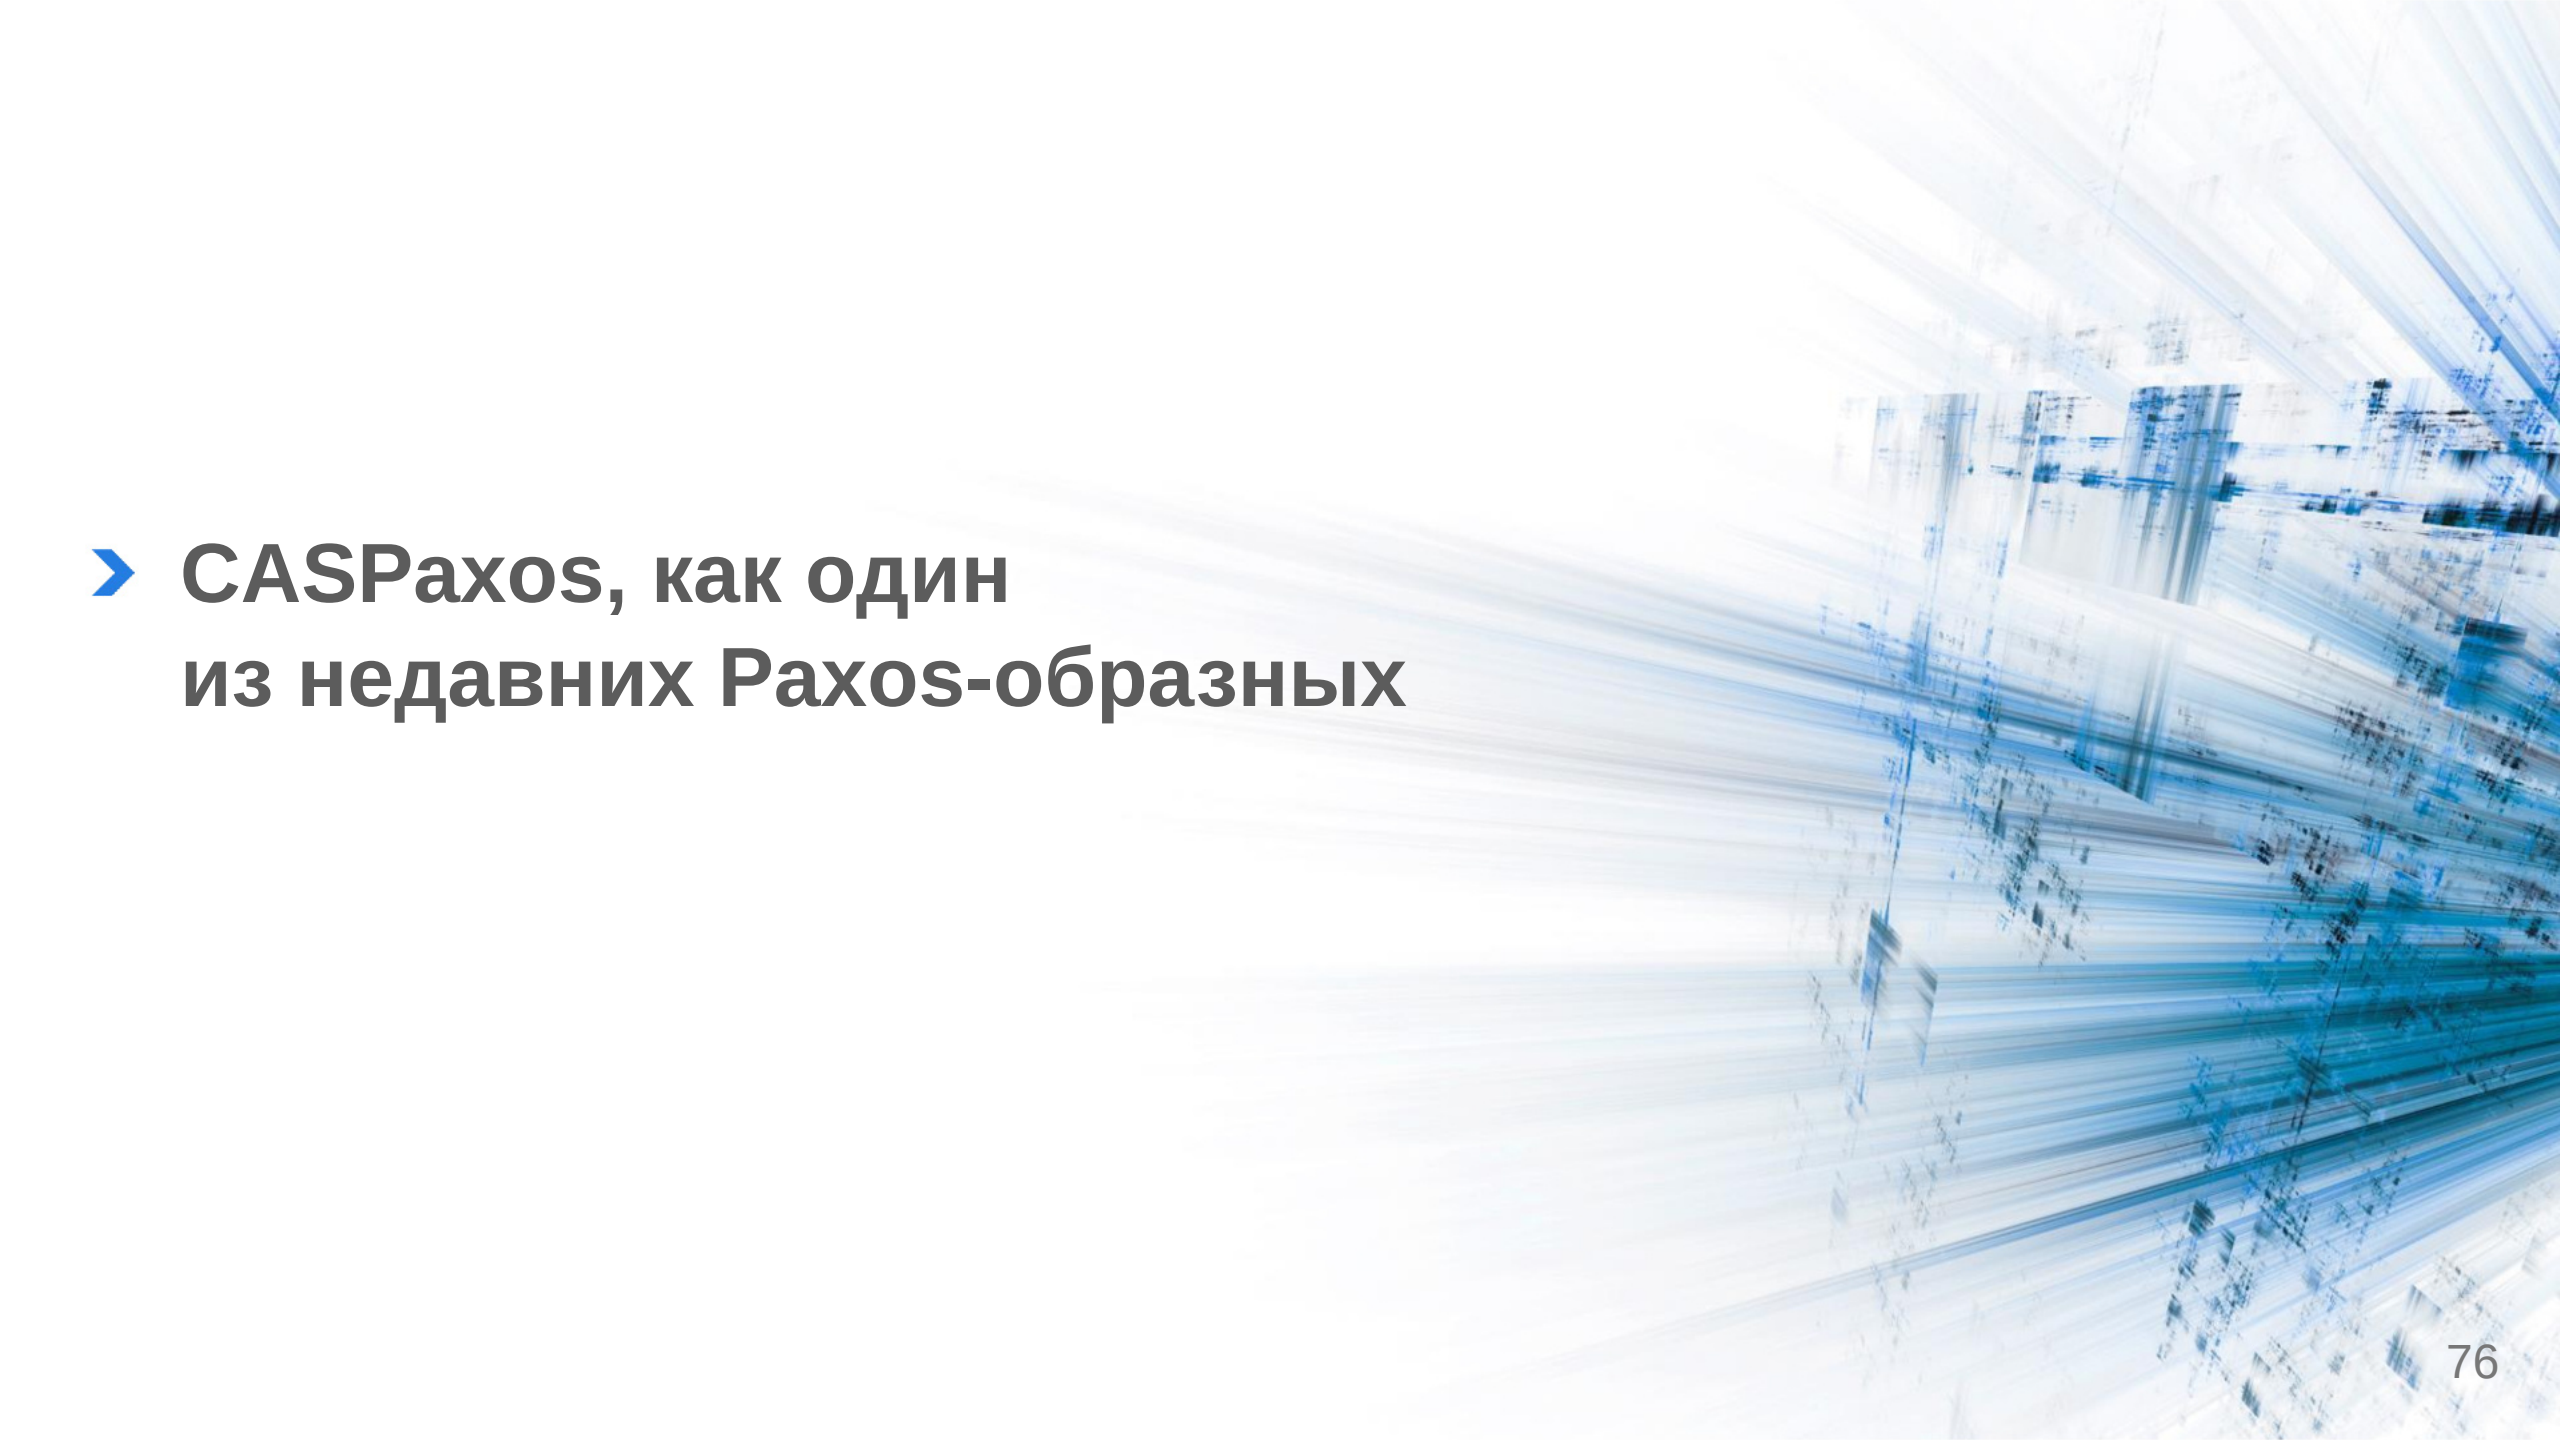

CASPaxos

- CASPaxos (D.Rystsov, 2018) - p2p, replicated state
- CAS - compare-and-set/compare-and-swap
- Модифицирует Paxos (Synod), а не просто использует его как компонент для построения системы

Основы CASPaxos

- Использует один регистр (объект)
- Вводит несколько ролей для процессов:
  - Clients: клиенты системы, отправляют запросы к Proposer
  - Proposers: принимают запросы клиентов, генерируют уникальные номера (proposal ID) и общаются с Acceptors
  - Acceptors: могут принимать предложения Proposers, хранят принятое состояние
- Для сохранения работоспособности системы до `F` отказов, нужны `2F + 1` Acceptors

Фаза 1

Client

Proposer

Acceptor'ы

1) Отправляет функцию ***f***.

2) Генерирует номер бюллетеня ***B*** (seq + ID) и отправляет сообщение **prepare** вместе с ***B*** acceptor'ам.

3) Если уже видел номер больше ***B***, возвращает сообщение о конфликте.
Иначе сохраняет ***B*** в качестве записи-обещания и возвращает ∅ или <принятое_значение, его_номер_бюллетеня>.

4a) Ждет ***F + 1*** подтверждений.
Если все они содержат ∅, берет ∅ в качестве текущего состояния.
Иначе берет значение с наибольшим номером бюллетеня.

Фаза 2

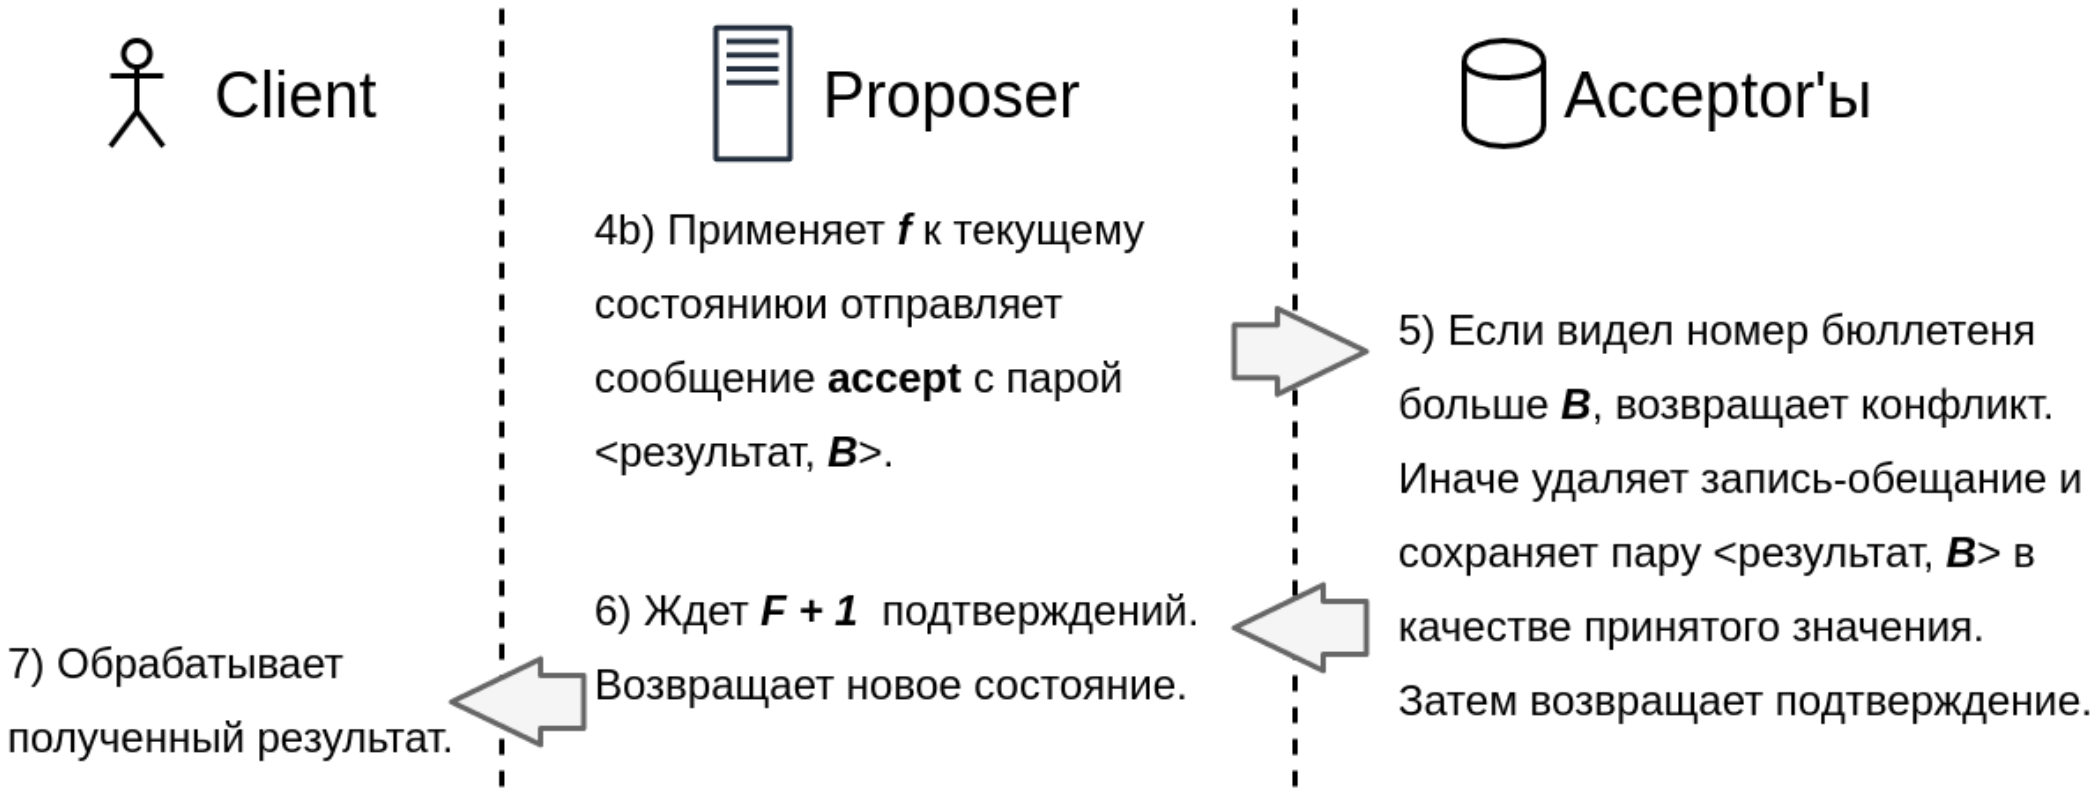
Client
Proposer
Acceptor'ы
4b) Применяет *f* к текущему состояниюи отправляет сообщение **accept** с парой <результат, *B*>.
5) Если видел номер бюллетеня больше *B*, возвращает конфликт. Иначе удаляет запись-обещание и сохраняет пару <результат, *B*> в качестве принятого значения. Затем возвращает подтверждение.
6) Ждет *F + 1* подтверждений. Возвращает новое состояние.
7) Обрабатывает полученный результат.

Связь с Synod

CASPaxos эквивалентен Synod, если взять функцию:

```
x -> if x = ∅ then val0 else x
```

CAS регистр на основе CASPaxos

Чтение:

```
x -> x
```

Инициализация значением `val0`:

```
x -> if x = ∅ then (0, val0) else x
```

Запись значения `val1` при условии версии `3`:

```
x -> if x = (3, *) then (4, val1) else x
```

Хранилище пар ключ-значение на основе CASPaxos

- Хранилище - это набор именованных экземпляров CASPaxos, по одному на ключ
- Преимущества и недостатки подхода в сравнении с тем же Raft выходят за рамки доклада

Pet-проект: CASPaxos на Node.js

https://github.com/gryadka/js (Node.js - proposers, Redis - acceptors)

||

\/

https://github.com/puzpuzpuz/ogorod (Node.js - proposers & acceptors)

P.S. Ура! Наконец-то дошли до Node.js! 🐢

Ogorod

- 558 строк кода
- И proposers, и acceptors живут в одном экземпляре Node.js
- Данные хранятся in-memory
- Внешняя и внутренняя коммуникация - HTTP

Пример использования

```
$ curl -X PUT http://localhost:8080/api/test \
  -H "Content-Type: application/json" \
  -d '{"foo":"bar"}'

{"version":0,"value":{"foo":"bar"}}
```

Пример использования

```
$ curl -X POST http://localhost:8080/api/test/cas \
  -H "Content-Type: application/json" \
  -d '{"version":0,"value":{"foo":"bar"}}'

{"version":1,"value":{"bar":"baz"}}
```

Чего не хватает до production-ready?

- Применить оптимизации для Paxos, например, CASPaxos 1RTT
- Поддержка динамической конфигурации, включая версионирование и сохранение на диск
- Поддержка операции delete. Нужен фоновый процесс аля GC (см. статью)
- Интеграция со встраиваемым хранилищем ключ-значение, например, RocksDB
- Перейти с коммуникации для внутренних нужд по HTTP к plain TCP
- Обработка ошибок и логирование
- И много чего еще

Подходит ли Node.js для реализации алгоритмов консенсуса?

- ☑️ Хорошая производительность при I/O-bound нагрузке
- ☑️ Зрелые стандартные модули и инструменты
- ☑️ Стабильная и развитая экосистема

Призыв к действию

- Распределенных систем бояться - на server-side не ходить
- Все, кому интересны высокопроизводительные библиотеки (и распределенные системы) - welcome
- https://github.com/hazelcast/hazelcast-nodejs-client
- P.S. Contributions are welcome as well

Спасибо за внимание!

Полезные книги и ссылки

- Designing Data-Intensive Applications, Martin Kleppmann, 2017
- CASPaxos: Replicated State Machines without logs, Denis Rystsov, 2018 - https://arxiv.org/abs/1802.07000
- Paxos Made Simple, Leslie Lamport, 2001 - https://lamport.azurewebsites.net/pubs/paxos-simple.pdf
- https://raft.github.io/raft.pdf
- https://jepsen.io
- https://martin.kleppmann.com/2015/05/11/please-stop-calling-databases-cp-or-ap.html
- https://vadosware.io/post/paxosmon-gotta-concensus-them-all/